

Harness 工程方法

模型权重之外、决定系统能否稳定交付的那一层。三款产品：小办 | 经历翻译官 | 缓择星球。

一、这一层是什么（定义与闭环）

Harness = Agent - Model。把模型拿掉之后剩下的全部工程层，就是它。2026 年 2 月由 Mitchell Hashimoto 提出，LangChain 给出上述最简拆法。

它由八层构成，但本质不是一个功能清单，而是一个闭环——闭环转起来才叫 harness 工程，只堆功能不回写叫半套。

八层

约束（什么绝对不能做） | 编排（多步怎么串） | 记忆（跨轮次记什么） | 检索（给模型看什么材料） | 工具（能做什么动作） | 护栏（出错怎么办） | 可观测（出问题怎么查） | 评测（怎么知道变好了）

闭环

约束 → 执行 → 观测 → 评测 → 回写约束。三个项目都断在这条环上的不同位置，而不是「没有 harness」。

二、八层覆盖矩阵（逐格实读判定）

层	小办	经历翻译官	缓择星球
1 约束	部分：29 个 Schema，阈值原为硬编码	部分：集中在提示词层	最弱：仅提示词祈使句，无转移表
2 编排	最强：13 节点 / 5 条件分支	部分：4 个手写编排函数	完整：中控状态机 + 四 Agent 串行
3 记忆	有：会话存储	缺：消息全量透传	最强：全局记忆三件套
4 检索	最强：标准QA + 向量 + 关键词 + 二次检索	轻量：关键词打分 top_k=8，无召回评估	部分：场景话术模板检索
5 工具	部分：存储可用，工具目录为空	缺	有：抉择存档、碎片点亮
6 护栏	有：三级兜底 + 冲突专属兜底	最强：三条模板兜底 + OCR 降级	设计层：唯一回流路径
7 可观测	已补：逐节点 JSONL trace	仅静态：只有知识库概况端点	缺
8 评测	已建成：118 例分层集 + 回写记录	缺	仅 1 个前端单测
合计	6 / 8	3.5 / 8	4.5 / 8

读法：这张表的价值不在总数，而在每一列缺失的位置不同——那说明是各自的阶段性取舍，而不是方法问题。

三、三个项目，断在闭环的不同位置

小办

闭环走到评测但没回到约束——报告出来之后没有「据此改约束」的动作，跑完就存档。这是三处里最薄的一环，也是本轮投入最重的地方（已闭合，见第 2 页）。

经历翻译官

闭环只走到执行。有编排、有检索、有兜底，但出场没有记录，也没有测试集；护栏是三者中最标准的，却没有任何数据证明它有效。要先补观测，再补评测。

缓择星球

闭环的起点建错了地方。架构文档反复强调「绝不越权、绝不串岗、禁止循环」，但全是提示词祈使句，代码层没有拦截非法转移的转移表。要先补约束。

Harness 工程方法

已落地的部分：小办评测台。以及四条判断准则、明确不做的事、必须主动说明的口径。

四、唯一成型的组件：小办评测台

四项升级：分支断言实装（期望分支归一成允许集合再比对） | ERROR 与 FAIL 分离（只有传输层原因自动重试） | HTTP 契约模式为默认（测用户真实走的路） | 版本对比（存档 + 基线改善与回归明细）。用例与判定函数一律 import 复用而非复制，避免两套实现漂移。

断言有效性实测：人为注入分支漂移后，三种口径的反应完全不同。

口径	分支正常	注入分支漂移	结论
新口径（含分支断言）	99.2%	12.7%	能感知漂移
旧口径（分支固定给分）	99.2%	99.2%	分支全错也照样满分
仅分支断言通过率	100.0%	11.2%	13/116，等于含全局兜底的用例数

旧口径恒为 99.2%，是原脚本对「路由对不对」默认白送 30 分。先证明尺子准，再谈尺子量出来的数。

五、回写记录与关键读数

回写记录	R1 至 R36 共 10 轮，每轮一行：触发用例 改动位置 改前改后读数 驱动证据 回归复测。期间修复 D1 至 D6 六个生产缺陷，含「答案正文输出成 dict」（影响 67.8% 请求）。
关键读数	修复 D1/D2 后：全命中 16.9 → 23.7%，50% 口径 46.6 → 51.7%，宽松口径 58.5 → 63.6%；三项均 ≥5.1pt，远超噪声上限。
噪声标定	同一配置连跑两次：strict ±0.8pt half ±0.9pt anyhit ±1.7pt，且 34/118 条答案文本会变。此线以下不作为改动有效的证据。
跨模型	换生成厂商后终端分支分布逐格相同（正常 106 兜底 11 冲突 1），全命中与宽松口径逐位相同；50% 口径差 2.5pt，逐例看全是用词波动。
语义判官	关键词按一半权重静默放过「必须转人工」，语义判官抓住，换模型后两轮独立复现；判官验证含阴性对照（标注全反转后 45/45 掉到 0/45）。
判读铁律	离散量给强结论（分支分布、字段是否写入）；文本类指标给弱结论。

六、四条判断准则与明确不做

准则	① 按「错一次的代价」分层 ② 先闭环后加层 ③ 能写进代码的不写提示词 ④ 每层都能单层开关（配置写坏时回落默认值，行为与改动前一致）。
不做	分布式链路追踪 在线 A/B 平台 自动化 CI 门禁 向量库选型对比 多租户与权限体系 自建 LLM 网关。这些是平台级团队的基础设施，做在此处只是维护负债。

七、诚实边界（面试必须主动说明）

- 绝对分不能替换简历数字：本套评测用替代语料与另一家模型，与线上归档属不同运行时、不同判定器下的两个数，只作结构性诊断；「评测台已建成可运行」也不等于「已产出可外推的质量结论」。
- 自评偏差未彻底消除：判官与被测同厂商，只能说未观察到，不能说已消除；标注集为单方判定，不是人工双标。
- 评测集本身需要 lint：已查出两条「期望词包含禁止词」的矛盾用例，无论系统多好都不可能通过。
- 不适用：单次性任务、纯静态页、形态探索期、无稳定输入分布的环节。