

缓择星球·成本账（含腾讯云后端部署）

基于项目真实工程（LLM调用点、内置价格表、Dockerfile / CloudBase部署）逐项拆
项目：缓择星球（慢慢选）· AI多智能体决策助手| 2026-09配置

总览结论

缓择星球的月成本，大头是LLM，不是服务器：

- 一次完整决策会话≈ 0.03-0.06元（qwen-turbo / deepseek混用）；中低活跃（月3000次会话）LLM约120-180元/月
- 腾讯云CloudBase云托管：1个容器按量常驻≈ 90-130元/月；支持缩容到0，低频期近乎0成本

一句话：选对模型+选对部署伸缩策略，能把成本拉开10-20倍。

1.模型与调用结构（真实工程）

Agent	职责	主模型（2026-09配置）	备用模型	内置价（元/百万in•out）
Agent1	需求挖掘/追问	qwen-turbo（降级备deepseek）	deepseek-chat	qwen-turbo 0.3 / 0.6
Agent2	方案检索/候选生成	deepseek-chat	qwen-turbo	deepseek-chat 1 / 2
Agent3	反向纠偏/唱反调	qwen-turbo	deepseek-chat	qwen-plus 0.8 / 2（部分路由）
Agent4	代价预演/权衡	deepseek-chat（复用agent2）	—	—

工程内置LLM_PRICING_CNY_PER_1K价格表+observ.metric_inc("llm_prompt_tokens_total"...)
逐调用埋点——成本是能对账的，不是估的。

USE MOCK=false才走真实LLM；每角色还有同厂商降级/跨厂商fallback。

2.一次完整决策会话的成本

一次会话（"该不该换工作" ->输出利弊清单）≈ 8-12次LLM调用（Agent1采集偏好2-3、Agent2出方案1-2、Agent3唱反调1-2、Agent4预演1-2、可能回流重试）。

项	估算	说明
单次调用输入	≈ 2000-3000 token	角色system prompt + 场景知识库注入+会话状态+历史摘要
单次调用输出	≈ 400-800 token	追问/候选/对比表/预演卡
一次会话in / out	≈ 25000 in / 6000 out	按10次调用取中
DS为主价	≈ 0.025 +0.012 = 0.037元/会话	deepseek-chat 1 / 2元每百万
qwen-turbo价	≈ 0.008 +0.004 = 0.012元/会话	turbo更便宜
若误用qwen-max	≈ 0.5 +0.36 ≈ 0.86元/会话	贵~20倍（这就是"选错模型"的代价）

关键结论：Agent产品的成本不取决于调用次数，取决于单步的上下文大小+每步输出是否收敛。

缓存用户历史、只注入相关场景知识（不做全库灌入）、强约束输出JSON，都是直接压in/out的手段。

3.规模化（LLM部分）

月会话量	场景	LLM月成本（turbo+DS混用~0.03/会话）	qwen-max全换
3000（中低活跃）	日活~100的早期产品	≈ 90-180元	≈ 2,600元
3万（稳定增长）	日活~1000	≈ 900-1,800元	≈ 2.6万元
30万（放量）	面向市场投放	≈ 0.9-1.8万元	≈ 26万元

4.腾讯云后端部署成本（CloudBase）

4.1部署形态（真实工程）

项目	形态	依据
缓择星球	CloudBase云托管（CloudRun容器模式），服务名manmanxuan，FastAPI + uvicorn单worker，PORT注入，就绪探针/api/health	Dockerfile + cloudbaserc.json（envId: huanzexingqiu-d9gpqhjwi2bf78965）
数据层	会话/画像->Redis（REDIS_URL），决策归档->Postgres（DATABASE_URL）	core/config.py
前端	小程序（微信生态免费承载）+ Web静态（GitHub Pages免费）	—

4.2计费口径（腾讯云CloudBase，2025-2026公开价）

云托管按量价：

- CPU ≈ 0.086元/核·小时（0.000024元/核·秒）| 内存 ≈ 0.043元/GiB·小时
- 免费额度：每个账号1个免费环境 ≈ 1核2 GiB常驻30天（体验期）
- 支持缩容到0：无请求不产生费用

部署档位	说明	月成本
免费额度/个人版	体验、原型、早期低活	0 - 19.9元
按量常驻1核2 GiB x1服务	缓择星球保活（正式体验不掉线）	≈ 90-125元/月
Redis + Postgres	CloudBase云数据库/轻量托管起步	≈ 50-150元/月（小规格）

注：云托管按量价存在新旧两档口径（旧PDF：CPU 0.055/核·时、内存0.032/GiB·时；新文档：约0.086/0.043），此处取新口径，实际以控制台出账为准。

4.3缓择星球月度总账（中低活跃）

项	月成本（中低活跃）
LLM：缓择星球（qwen-turbo + deepseek）	≈ 100-180元
腾讯云托管（常驻1核2 G）	≈ 90-125元
Redis / Postgres	≈ 50-150元
合计	≈ 240-455元/月

若走"个人版+免费额度起步+缩容0"，前1-2个月可以压到0-100元跑通验证。

放量后再切按量常驻+用量缓存，模型选型守死qwen-turbo/DS，不到万元级不会碰qwen-max。

5.核心结论

缓择星球是四Agent决策机，一次会话8-12次调用，我把单次成本压到3-5分钱——

靠两件事：模型分层（需求挖掘/唱反调用便宜的turbo，检索/权衡用deepseek）和每步上下文收敛（只注入相关场景知识，不灌全库）。

腾讯云后端我选CloudBase云托管，能缩容到0、按量计费——早期体验期一个月几十块钱，正式放量一核两G也就一百出头。

而且工程里从第一天就埋了token用量打点，成本不是估的，是能对账的。

为什么不用更贵的模型（如qwen-max）？

max贵20倍，但多Agent场景的瓶颈不在"模型多聪明"，在"每步上下文喂得对不对、输出收不收得住"。

turbo + 强约束 + 结构校验已经达到评测标准，没必要为边际提升付20倍成本——这是产品判断，不是技术洁癖。

6.假设与诚实披露

- Token量为估算区间（按提示词长度+场景知识注入量推断），缓择工程已埋usage打点、可换真实值对账。
- 模型单价取"项目内置价格表+官方公开价"量级：qwen-turbo 0.3/0.6、deepseek-chat 1/2、qwen-max 20/60（元/百万），实际以控制台为准。
- 腾讯云价格取2025-2026公开文档口径（按量vs套餐存在差异），云托管支持缩容到0，故低频期趋近0。
- 未计：CDN/静态流量（量小）、对象存储、微信小程序认证年费（一次性）、人工运维（0，纯serverless）。
- 缓存策略：会话级结果缓存、知识上下文按需注入、模型分层、输出max_tokens收紧。