

经历翻译官·成本账（含腾讯云后端部署）

基于项目真实工程（backend/config.py、内置价格表、Dockerfile部署）逐项拆
项目：经历翻译官·AI求职诊断工具| 2026-09配置

总览结论

经历翻译官的成本大头也是LLM，不是服务器：

- 一次完整报告≈ 0.02-0.05元（DeepSeek主模型）；月3000次报告约50-150元/月
- 后端为纯无状态单容器，腾讯云CloudBase可缩容到0，低频期近乎0成本

一句话：守死DeepSeek / qwen-plus主模型+缩容0部署，个人/小团队跑通成本极低。

1.模型与调用（真实工程backend/config.py）

用途	模型	说明
主生成（报告/改写/聊天）	deepseek-chat（默认，可切qwen-plus）	报告temp 0.85、改写0.4、聊天0.75
OCR /图片理解	qwen-vl-plus（视觉）	仅上传简历截图时触发
架构	LangChain ChatOpenAI（OpenAI兼容），无数据库（状态存浏览器）	后端是纯无状态单容器

2.一次"完整使用"的成本（用户完整走一遍）

一次用户会话≈ 1次报告+1-3次局部改写+若干轮聊天追问：

动作	输入（估）	输出（估）	DS价（1 / 2元每百万）
生成报告（6大模块）	≈ 7000-9000（system prompt ~3500 +知识库top注入+用户经历）	≈ 3000-4500	≈ 0.016-0.027元
局部改写x2	≈ 2000 x 2	≈ 500 x 2	≈ 0.006元
聊天x5轮	≈ 1000 x 5	≈ 400 x 5	≈ 0.009元
OCR（可选1张简历图）	图≈ 1500 token	500	qwen-vl ≈ 0.01-0.05元
合计/用户			≈ 0.04-0.09元（DeepSeek主）

3.规模化（LLM部分）

月报告数	月成本（≈0.06/次完整使用）	备注
3000	≈ 180元	早期流量足够覆盖
30000	≈ 1,800元	若切qwen-max会到1.2万+，必须守DS/plus

4.腾讯云后端部署成本（CloudBase）

4.1部署形态（真实工程）

项目	形态	依据
经历翻译官	同为FastAPI容器（无状态，无数据库），可用同一账号再起一个服务	backend/Dockerfile
前端	Web静态（GitHub Pages免费）	—

4.2计费口径（腾讯云CloudBase，2025-2026公开价）

云托管按量价：

- CPU $\approx$ 0.086元/核·小时 | 内存 $\approx$ 0.043元/GiB·小时
- 免费额度：每个账号1个免费环境 $\approx$ 1核2 GiB常驻30天（体验期）
- 支持缩容到0：无请求不产生费用

部署档位	说明	月成本
免费额度/个人版	体验、原型、早期低活	0 - 19.9元
经历翻译官按需（缩容0 + 冷启动可接受）	低频时0，活跃期临时拉起	$\approx$ 0-60元/月

注：云托管按量价取2025-2026公开文档新口径，实际以控制台出账为准。

4.3经历翻译官月度总账（中低活跃）

项	月成本（中低活跃）
LLM：经历翻译官（DeepSeek主）	$\approx$ 50-180元
腾讯云托管（按需缩容0）	$\approx$ 0-60元
合计	$\approx$ 50-240元/月

纯无状态容器+缩容0，低频期托管成本趋近0；放量后切常驻并守DS/plus，不当碰qwen-max。

5.核心结论

经历翻译官是"生成型诊断"产品，一次完整使用（1报告+改写+追问） $\approx$ 0.04-0.09元，月3000次仅约180元。

关键控制点：主模型守死DeepSeek（报告/改写/聊天）、OCR仅按需触发、长文生成靠上下文裁剪而非堆模型；后端纯无状态单容器，可缩容到0——早期几乎零服务器成本。

工程上从配置层就锁定模型与温度，成本是稳定可预期的，不是跑一次看一次。

6.假设与诚实披露

- Token量为估算区间（按提示词长度+知识库注入量推断），建议补一行usage日志换成真实值对账。
- 模型单价取"项目内置价格表+官方公开价"量级：deepseek-chat 1/2、qwen-plus约1/2、qwen-vl-plus单独计费，实际以控制台为准。
- 腾讯云价格取2025-2026公开文档口径，云托管支持缩容到0，故低频期趋近0。
- 未计：CDN/静态流量（量小）、对象存储、人工运维（0，纯serverless）。
- 缓存策略：会话级结果缓存、知识上下文按需注入、输出max_tokens收紧。