




PRD-慢慢选

前言

💡 为什么写这份文档

当前 AI 产品的主流叙事是"更快、更准、更全"——ChatGPT 秒回万知，小红书千人千面，京东导购一键下单。但快不等于对，多不等于好。在信息过载的时代，真正困住用户的不是"找不到答案"，而是"不知道自己到底要什么"。

慢慢选诞生于一个反直觉的观察：选择困难不是知识匮乏，而是认知偏差与情绪焦虑的叠加。买耳机查 3 天、辞职能纠结 2 个月、和 crush 发消息删改 7 遍——这些行为的背后，是 Barry Schwartz 所说的"选择悖论"、是损失厌恶、是后悔厌恶。现有 AI 只会"你问我答"，不会帮你"想清楚自己到底要什么"。

这份 PRD 不是一份功能清单，而是一份行为经济学产品化的设计蓝图。它试图回答一个问题：如何用多 Agent 编排技术，把"唱反调"和"后悔预演"变成可工程化、可评估、可迭代的产品机制。

文档结构导读

本文档按"为什么做 → 是什么 → 怎么做 → 怎么验证"的逻辑展开：

本文遵循「为什么做→是什么→怎么做→怎么验证」逻辑排布：

第 1-6 章（产品概述、名词释义、流程图、需求背景）：解释立项缘由，结合市场空白、理论依据、竞品短板论证产品价值。

第 7-14 章（功能需求、非功能需求）：明确产品形态，介绍产品机制与技术架构规范。

第 15-17 章（埋点设计、测试用例、风险与优化方案）：阐述验证方案，搭建指标体系、分层测试规则与风险改进路径。

第 18 章（进度计划）：说明落地方式，规划 2.5 周 MVP 排期、里程碑与风险缓冲方案。

关于技术选型的说明

文档中明确不使用扣子/Dify 等低代码平台，原因有三：三个 Agent 的协同逻辑（挖需求→追问→检索→唱反调→可能回流）需要精细的状态机控制；Agent3"唱反调"需要复杂的 Prompt 工程与 few-shot 设计；这个项目是展示技术深度的主力，必须体现对 LangGraph、Agent 编排、Memory 设计的理解。

一个核心假设

这份 PRD 背后的核心假设是：高敏感人群愿意为"降低后悔率"付出时间成本。如果假设成立，慢慢选的价值不在"快"，而在"对"；如果假设不成立，产品需要向"效率工具"方向转型。MVP 阶段的回访数据将直接验证这一假设。

不是帮你选最快的，是帮你选最不会后悔的。

这是慢慢选的起点，也是这份文档的终点。

一、版本信息



版本号：1.0



创建日期2026-7-31



审核人

二、变更日志

时间	版本号	变更人	主要变更内容
2026-7-31	v1.0	韩佳雪	初始版本，完成产品概述、功能清单、流程设计
2026-8-7	v1.1	韩佳雪	升级为 四Agent完整架构 ，新增Agent4全局风控校验智能体；全流程嵌入风控校验节点；新增Agent4专属Prompt、模型调度、埋点、评测指标、测试用例、降级兜底；更新业务时序、状态机逻辑、上线验收标准，补齐所有AI强制模块，定稿可直接交付


三、文档说明

名词解释

术语	英文/缩写	定义	产品内应用场景
LangGraph	LangGraph	LangChain 团队开发的多 Agent 编排框架，基于 状态机（StateGraph） 实现节点流转、循环和条件分支	承载四Agent全链路挖掘→生成→纠偏→风控→预演→回访闭环
Agent1 需求挖掘智能体	Demand Agent	负责多轮递进式需求挖掘、矛盾识别、隐性约束挖掘	收集用户预算、场景、核心诉求、历史后悔模式，完成字段补齐
Agent2 方案生成智能体	Retrieve Agent	基于用户完整需求，检索知识库并结构化输出选项卡片	动态控制选项数量，输出优缺点、后悔风险、个性化匹配内容
Agent3 反向纠偏智能体	Devil Agent	强制打破用户确认偏误，主动输出反向视角与非首选方案	解决用户执念、单一认知、冲动决策，降低远期后悔概率
Agent4 全局风控校验智能体	Risk Guard Agent	全流程后置三层校验：合规校验、事实幻觉校验、情绪强度校验	拦截违规需求、驳回模型幻觉、防止Agent3过度抬杠、保护用户体验与内容安全
字段守卫	Field Guard	需求挖掘阶段的强制校验机制：未满 4 个必填字段，不允许跳转到检索节点	防止 Agent1「聊飘」、过早给选项；确保隐性约束被充分挖掘
强弱唱反调降级	Weak/Strong DA	正常强反向纠偏，用户抵抗或话术过激自动降级为风险提示	平衡产品差异化能力与用户体验
征询式 Memory	Consultative Memory	引用用户历史时采用询问语气（「你上次说 X，这次还是吗？」），而非直接推送	避免「我记得你买了 XX」的 creepy 感，让用户主动确认
决策预演	Regret Rehearsal	用户选定选项后，AI 模拟「3 个月后」场景，提示最可能的后悔点	基于 预演后悔 理论，让用户提前想象后悔，降低实际后悔率
选择悖论	Choice Paradox	Barry Schwartz 理论：选项越多，决策满意度和行动意愿越低	按决策风格动态控制选项数量（完美主义 2 个 / 冲动型 3 个）
后悔厌恶	Regret Aversion	人们为避免后悔，宁愿维持现状或拖延决策	产品核心价值主张来源；回访闭环量化后悔，形成数据飞轮

四、需求背景、痛点拆解、理论支撑与量化目标

痛点拆解



- 1

选择困难
- 2

└─ 信息过载：选项太多，无法有效比较
- 3

└─ 隐性约束不明：用户说不清自己真正在意什么
- 4

└─ 认知偏差：确认偏误（只看好的一面）、双曲贴现（高估当下）
- 5

└─ 后悔厌恶：害怕选错 → 不敢选 → 拖延 → 更焦虑

行为经济学理论支撑

理论	定义	产品映射
选择悖论（Barry Schwartz）	选项越多，决策满意度和行动意愿越低	动态控制选项数量（2-3个），按决策风格调整
后悔厌恶（Regret Aversion）	人们为避免后悔，宁愿维持现状	回访机制量化后悔，"后悔预演"降低预期后悔
双曲贴现	现在效用 > 未来效用，导致冲动决策	唱反调时引入"3个月后视角"
损失厌恶（Loss Aversion）	损失的痛苦 > 获得的快乐	选项卡片突出"如果放弃B，你会失去什么"
确认偏误	倾向于寻找支持自己观点的信息	Agent3强制推送反面信息

竞品分析

慢慢选不是"更好的ChatGPT"，也不是"AI版小红书"——它是第一个把"降低后悔率"作为北极星指标、用行为经济学设计交互、用多Agent编排实现"唱反调"的决策辅助工具。

竞品	类型	优势	劣势	慢慢选的差异化
ChatGPT/Claude	通用AI助手	知识面广、推理强	被动应答、不会追问、不唱反调	主动挖掘+强制反向+回访闭环
小红书/什么值得买	UGC导购社区	真实用户体验	信息过载、选择悖论、无个性化	AI结构化筛选+行为经济学干预
京东智能导购	电商AI客服	与交易链路打通	目标导向（促成成交）、不考虑后悔	以用户长期满意度为目标

竞品关键缺陷拆解（慢慢选的机会点）

缺陷	具体表现	慢慢选的解法

AI讨好倾向	用户说想买A，AI只会找A的优点附和	Agent3强制唱反调，必须推荐B/C并给理由
平台成交导向	导购平台目标是GMV，不关心用户买了是否后悔	回访闭环量化后悔率，以长期满意度为北极星指标
信息过载 paralysis	100篇评测反而让决策者更焦虑	按决策风格动态控制选项数量（2-3个），"少即是多"
无记忆关联	每次对话从零开始，无法引用历史	征询式Memory："你上次说X，这次还是吗？"
无后悔干预	没有任何产品在"买后后悔"环节做闭环	决策预演 + 定时回访 + 后悔数据沉淀

量化业务目标（MVP阶段）

所有目标均为可量化、可验收指标，无模糊描述：

- 1. 核心北极星指标：用户决策7日后悔率 ≤ 40%
- 2. 辅助业务指标：对话完整完成率 ≥ 70%、Agent3唱反调有效成功率 ≥ 30%
- 3. 体验指标：用户对反向建议负面反馈率 < 5%、平均决策时长 ≤ 5分钟
- 4. 数据沉淀指标：MVP上线30天累计真实回访数据 ≥ 50条

五、产品四层架构与完整业务闭环

整体四层技术架构

应用层：多轮对话交互、结构化选项卡片、唱反调气泡、决策预演弹窗、回访问卷、决策档案可视化、风控拦截提示弹窗

AI能力层（核心）：LangGraph状态机、四Agent协同编排、字段守卫、征询式记忆、强弱降级策略、全局三层风控校验、后悔预演推理

调度服务层：主备模型调度、流量熔断、Token成本限制、超时重试、降级兜底

数据底层：场景Schema库、用户决策档案、后悔记录库、会话状态库、埋点日志库、风控拦截日志库

四Agent职责完全解耦

Agent1 需求挖掘：递进式收集结构化需求，识别用户需求与历史行为矛盾，保证需求完整、真实、无遗漏

Agent2 检索生成：基于完整需求检索知识库，输出标准化、可对比、无虚构的选项卡片，动态控量避免选择悖论

Agent3 反向纠偏：打破用户主观偏好，输出有效反向视角，纠正确认偏误，可控强度避免对抗

Agent4 全局风控守卫（新增核心）：全节点三层校验（合规+幻觉+情绪），拦截违规、驳回虚构、压制过激话术、保障会话安全与体验兜底

完整业务闭环时序（嵌入Agent4全节点校验）

会话启动→场景识别&Schema加载→Agent1需求挖掘 → Agent4合规校验（拦截违规诉求）→字段守卫校验是否集齐4项核心字段→字段不足回流重挖

字段集齐→Agent2生成结构化方案 → Agent4事实幻觉校验（虚构参数直接驳回重生成）→方案放行展示

用户浏览方案→Agent3强制反向唱反调 → Agent4情绪强度校验（过激话术强制降级）→纠偏内容放行

用户选定方案→决策预演风险推演 → Agent4焦虑风控校验（禁止恐吓式推演）→风险展示

用户确认决策→分层预约回访→收集后悔数据→沉淀用户决策画像与风控日志→迭代Agent推理与风控规则

六、意图体系设计

意图分级与边界定义

一级意图（核心业务意图）

- 1. 决策咨询意图：用户主动寻求购物、职业、旅行等场景决策建议（核心高频）
- 2. 决策确认意图：用户已有偏好，需要AI验证、辅助判断
- 3. 决策反悔意图：用户否定当前选项，需要重新梳理需求、更换方案

二级意图（辅助交互意图）

- 1. 疑问咨询意图：询问产品功能、使用规则
- 2. 情绪表达意图：吐槽、抵触反向建议、负面情绪宣泄
- 3. 无效闲聊意图：无关联日常对话、无决策需求

正负话术样例

正向意图样例（命中业务流程）

- 决策咨询：帮我选500元以内的通勤耳机、两个职场offer怎么选、规划周末旅行
- 决策确认：我想买这款耳机，帮我看看合适吗、这个offer值得去吗
- 决策反悔：这几个选项都不合适、我再重新想想、换几个方案

负向意图样例（触发兜底策略）

- 无效闲聊：你好、今天天气怎么样、随便聊聊
- 恶意对抗：你就是错的、不用你管、AI都是垃圾
- 违规提问：涉及政治、暴力、隐私信息查询

意图路由与兜底策略

1. 核心意图：直接进入对应场景决策流程，执行Agent流转
2. 辅助意图：轻量应答，不跳出当前决策会话，保留上下文
3. 无效/违规意图：触发兜底话术，终止无效交互，维持会话状态，不报错、不崩溃
4. 意图识别失败：默认保留当前挖掘流程，继续递进追问需求，不强行跳转

七、 功能需求

功能全景图



功能清单（按优先级）

模块	功能点	归属智能体	优先级	MVP 是否包含	备注说明
核心决策对话流 (主线 P0)	场景自动识别与 Schema 加载	系统调度层	P0	✓	自动识别购物 / 职业 / 旅游等场景，加载对应字段模板
	多轮递进需求挖掘 + 矛盾检测	Agent1	P0	✓	文字追问 + 卡片表单双模式收集需求，核心字段禁止跳转
	卡片式结构化需求收集	Agent1 + 交互渲染层	P0	✓	按需生成问卷卡片、单选 / 多选题，替代冗长文字问答
	结构化选项检索与卡片输出	Agent2	P0	✓	根据用户决策风格动态控制 2 级选项，避免选择悖论
	主动反向唱反调纠偏（强弱降级）	Agent3	P0	✓	产品核心差异化，打破确认偏误，纠偏后自动降级选项
	全流程三层风控校验（合规 + 幻觉 + 情绪）	Agent4（新增核心）	P0	✓	全节点后置校验：拦截违规诉求、识别幻觉、压制过激话术、保障合规
	决策后悔预演模拟	预演模块 + Agent4 校验	P1	✓	模拟 3 个月远期风险，Agent4 辅助决策，输出焦虑式输出
记忆档案系统	征询式 Memory 历史调用	Agent1 / Agent3 + Agent4 校验	P1	✓	引用历史决策数据先询问确认，避免记忆引用准确性，避免幻觉
	全链路状态机流转与降级兜底	调度层 + 四 Agent 协同	P0	✓	支持节点回流、重试、降级、重试失败后流程永续
	用户决策档案结构化存储	数据服务层	P1	✓	JSON 结构化存储决策偏好、决策历史、特征
	用户决策风格分类识别	Agent1 辅助识别	P1	○	MVP 简化手动标注，迭代版本增加语义 / 冲动型 / 执念型分类
	历史后悔数据沉淀	数据服务层	P1	✓	沉淀每轮决策的后悔风险、用户决策结果
	回访闭环系统	运营反馈层	P1	✓	按购物 / 职业 / 大额消费动态触发回访，提升满意度
	后悔率数据结构化记录	数据服务层	P1	✓	量化后悔分值、后悔原因、决策结果
数据运营与埋点	全链路四 Agent 行为埋点	数据服务层	P1	✓	覆盖 Agent4 风控拦截、驳回、决策数据
	决策日志可视化与匿名洞察	运营反馈层	P2	○	MVP 仅后台数据沉淀，迭代版本增加可视化洞察

功能详细说明

FR-001 场景识别与 Schema 加载

需求描述：用户输入首句对话后，系统自动识别决策场景，初始化对应标准化 RequirementSchema，加载场景专属追问字段与决策规则，为 Agent1 文字挖掘、卡片表单生成提供统一字段模板。

输入：用户自然语言对话（如「帮我选耳机」「两个工作 offer 怎么选」「规划旅游行程」）

输出：精准场景类型 + 对应完整 Schema 模板 + 初始化对话状态 + 空字段待挖掘标记

联动机制：场景识别完成后，系统自动生成**需求收集卡片草稿**，可一键弹出卡片收集模式；全程受Agent4 合规风控监听，若场景诉求违规直接拦截终止。

联动机制：场景识别完成后启动Agent1挖掘流程，全程受Agent4合规风控监听，若场景诉求违规直接拦截终止。

各场景Schema定义：

代码块

```
1  # 电商购物场景（耳机/数码/日用）
2  ShoppingSchema = {
3      "budget": {"type": "number", "required": True, "question": "你的预算是多
4      "usage_scenario": {"type": "string", "required": True, "question": "主要在什
5      "core_concern": {"type": "string", "required": True, "question": "你最在意什
6      "regret_history": {"type": "string", "required": True, "question": "上次买类
7      "time_pressure": {"type": "string", "required": True, "question": "这个决定
8  }
9
10 # 职业选择场景
11 CareerSchema = {
12     "salary_expectation": {"type": "number", "required": True, "question": "你的
13     "growth_priority": {"type": "string", "required": True, "question": "你更看
14     "commute_tolerance": {"type": "string", "required": True, "question": "你能
15     "team_culture_pref": {"type": "string", "required": True, "question": "偏好
16     "career_stage": {"type": "string", "required": True, "question": "处于职场新
17     "regret_pattern": {"type": "string", "required": True, "question": "过往择业
18 }
```

验收标准

- 1. 多场景识别准确率 ≥ 90%（覆盖购物、职业、旅游、消费、学习 5 类核心场景）
- 2. Schema 整体加载延迟 < 500ms，无卡顿、无加载失败
- 3. 异常违规场景可正常触发 Agent4 风控拦截，流程终止合规

4. Schema 可自动渲染为收集卡片表单，字段一一对应。

FR-002 多轮需求挖掘与卡片式需求收集（Agent1 核心能力，新增卡片模式）

需求描述

由 Agent1 主导双模式需求收集：模式 A（默认）：传统递进式文字对话追问；模式 B（可选）：自动渲染需求收集卡片，将 Schema 必填字段转化为可视化表单卡片，支持单选、多选、数值填写、文本输入，用户一次性批量填写需求。两种模式数据互通、共用同一套字段守卫机制；无论用户使用哪种模式填写，填满必填字段才可流转至 Agent2 生成方案。所有交互内容均经过 Agent4 合规校验。

核心执行机制

机制名称	详细说明
字段守卫机制	用户未填满 4 个及以上核心必填字段时，永久回流挖掘节点，禁止跳转到 Agent2 需求不全输出无效方案
需求矛盾检测机制	结合用户实时对话 / 卡片填写内容 + 历史 Memory 数据，主动识别需求冲突，如“既要轻量化又要高性能”，却因过往重设备佩戴不适后悔，主动点明隐性矛盾
双模式自由切换机制	对话过程中用户随时点击「一键填写表单卡片」按钮，即可切换卡片收集模式；卡片填完后，点击「继续对话」切回对话模式
递进式追问机制	文字模式下不做泛泛提问，基于已有信息精准补全缺失字段；卡片模式补齐全部必填字段后，才触发追问，保证追问的精准性和完整性
前置风控校验机制	Agent1 每轮输出、卡片表单提交内容，强制经过 Agent4 合规校验，拦截违规内容

卡片样式规则

- 1. 单张卡片承载 1~2 个 Schema 字段，避免表单过长造成视觉压力；
- 2. 枚举类字段（使用场景、核心关注点、团队偏好）渲染为单选按钮卡片；
- 3. 数值类字段（预算、薪资、通勤时长）渲染数字输入框卡片；
- 4. 回忆类开放式字段（后悔经历）渲染文本输入卡片；
- 5. 卡片底部附带「查看历史偏好」按钮，点击后以征询句式调取 Memory。

两种交互模式示例

模式 1：传统文字对话

用户：帮我选个耳机，预算 500 以内。

Agent1：500 以内选择很多。你主要在什么场景用？通勤、运动还是办公室？

Agent4 校验：内容合规、无异常，放行 用户：主要是通勤和办公室。

Agent1：好的。你最在意什么 —— 音质、续航、重量，还是降噪？

Agent4 校验：内容合规、无异常，放行 用户：续航吧，不想总充电。

Agent1：我注意到你上次买的耳机续航只有 4 小时，但你用了两年没换。你上次后悔过吗？

Agent4 校验：记忆引用合规、话术温和，放行 用户：有点后悔，戴久了耳朵疼。

Agent1：明白了。所以这次重量和佩戴舒适度可能比续航更重要？最后，这个决定急吗？ 用户：不急，可以想一周。

Agent4 最终校验：需求完整、话术合规，放行流转 系统✅需求收集完成，正在为你检索最优选项...

模式 2：卡片表单收集（新增）

用户：帮我选个耳机。系统弹出按钮：【文字慢慢聊】 | 【一键填表快速需求收集】 用户点击【一键填表快速需求收集】 依次弹出卡片： 卡片 1（数值卡片） 标题：你的耳机预算 输入框：_____ 元

卡片 2（单选卡片） 标题：使用场景 ☐通勤 ☐办公室 ☐运动 ☐居家

卡片 3（单选卡片） 标题：最看重的核心卖点 ☐音质 ☐续航 ☐轻量化佩戴 ☐降噪

卡片 4（文本卡片） 标题：之前买耳机有没有后悔的经历？简单说说

卡片 5（单选卡片） 标题：决策紧急程度 ☐当天就要选 ☐3 天内 ☐一周慢慢考虑

用户完整填写并提交卡片 → 系统自动校验字段全部补齐 Agent1：已收到你的全部需求，正在为你匹配耳机方案。Agent4 校验通过，流转至 Agent2 生成选项卡片。

混合模式示例

用户文字回复预算之后，不想继续打字，点击唤起收集卡片，补齐剩余字段，提交后直接进入下一流程。

验收标准

- 1. 纯文字模式：平均收集完整核心需求对话轮次 ≤ 5 轮
- 2. 卡片表单模式：完整收集需求仅需 1 次提交，耗时≤15 秒
- 3. 用户需求矛盾点识别率 ≥ 80%
- 4. 字段守卫 100% 生效，缺字段无论哪种模式都禁止流转
- 5. 挖掘阶段违规诉求 100% 被 Agent4 拦截
- 6. 卡片渲染成功率 100%，填写数据可无缝接入全局字段系统。

FR-003 选项检索与结构化输出（Agent2 核心能力）

需求描述：需求挖掘完成后，由 Agent2 调用场景知识库完成检索，根据用户实时决策风格动态控制选项数量，输出标准化结构化选项卡片。所有生成内容必须经过 Agent4 事实幻觉校验，存在虚构参数、虚假优势、不实数据直接驳回重生成。标准选项卡片结构不变，沿用原有 JSON 结构。

动态选项数量控制规则

用户决策风格	输出选项数量	设计理由
完美主义型	2 个	减少选择悖论，避免决策瘫痪
冲动型	3 个	增加对比维度，抑制冲动决策
心有所属型（有明确偏好）	1 个最佳 + 1 个反向对比	打破用户确认偏误，提供反向参考

Agent4 专属校验规则：严格核查价格、参数、功能、适配场景真实性，杜绝 AI 幻觉，驳回后自动触发 Agent2 重生成，连续 2 次驳回则强制放行并标记人工复盘。

验收标准

- 1. 单轮选项生成耗时 < 5s
- 2. 选项卡片 JSON 格式 100% 规范合规
- 3. 模型幻觉拦截率 ≥ 85%，无虚假参数输出
- 4. 选项数量动态匹配用户决策风格，无固定输出。

FR-004 主动反向唱反调（Agent3 核心差异化功能 · P0）

需求描述：由 Agent3 主导反向纠偏，针对用户明确偏好、主观执念、认知偏差，主动输出反向视角与风险提示，打破确认偏误。无论用户是文字填写还是卡片填写需求，Agent3 均可读取完整需求集进行纠偏；所有纠偏话术必须经过 Agent4 情绪强度校验，过激、尖锐、对抗性话术自动强制降级为温和风险提示。

核心执行规则

- 1. 强制挖掘用户需求自相矛盾点，不迎合用户主观偏好；
- 2. 用户明确偏向某一选项时，必须主动输出更适配的反向方案；
- 3. 调用历史 Memory 数据，必须采用征询式提问，不主观断言；
- 4. 话术风格为友好提醒，非抬杠对抗，服从 Agent4 情绪管控指令；
- 5. 最多 2 轮强唱反调，两轮后自动降级为弱风险提示。

验收标准

- 1. 心有所属执念场景下，反向纠偏成功率 ≥ 70%
- 2. 用户对反向话术负面情绪反馈率 < 5%
- 3. 过激话术可被 Agent4 100% 识别并强制降级。

FR-005 决策后悔预演（预演模块 + Agent4 风控）

需求描述：用户选定目标选项后，系统自动触发 3 个月远期场景模拟，输出个性化、场景化的后悔风险预判。预演内容由 Agent4 做焦虑风控校验，禁止恐吓式、极端化、制造过度焦虑的输出，仅做客观

风险提示。 示例不变。

验收标准

- 1. 用户选定选项后，预演功能 100% 触发，无遗漏
- 2. 预演内容与用户场景、痛点相关性 $\geq 80\%$
- 3. 无焦虑恐吓式输出，Agent4 风控拦截生效。

FR-006 征询式 Memory 调用（全 Agent 通用规则）

需求描述：Agent1、Agent3 调用用户历史决策、后悔记录、偏好数据时，不直接断言推送，采用征询式提问确认；在卡片收集模式下，卡片内可嵌入「调取我的历史偏好」按钮，点击后以征询句式展示过往偏好，降低监视感。同时由 Agent4 校验记忆引用准确性，杜绝虚假关联、错误匹配。

正反示例对比

❌ 错误：直接断言（易引发反感）	✅ 正确：征询式提问（产品标准）
我记得你上月买耳机后悔了	你上次反馈耳机佩戴不适，这次优先级还是续航优先吗
你择业一直看重薪资	上次你选择工作更看重薪资回报，这次的考量优先级有变1

验收标准

- 1. 用户历史记忆引用准确率 $\geq 80\%$
- 2. 记忆引用带来的用户负面反馈率 $< 5\%$
- 3. 错误记忆关联可被 Agent4 识别拦截。

FR-007 回访闭环系统

需求描述：根据用户决策场景类型，动态配置回访周期，定时触发弹窗回访卡片，结构化收集用户决策结果、后悔分值、后悔原因，沉淀数据用于模型迭代与指标统计。 回访不再是纯文字弹窗，统一使用回访收集卡片，提升填写完成率。

分场景回访时机规则

决策场景类型	首次回访时机	二次回访时机
电商小件购物	决策后 7 天	无
职业选择	入职 30 天	入职 90 天
短期旅游决策	行程结束后 1 天	无
大额消费决策	决策后 3 个月	决策后 1 年

回访卡片表单结构

- 卡片 1：单选「最终选择了哪一个方案」
- 卡片 2：单选「选择是否和 AI 推荐一致」
- 卡片 3：星级评分卡片「后悔程度 1~5 星」
- 卡片 4：文本卡片「满意 / 后悔的原因」
- 卡片 5：单选「重新选择会改变方案吗」

验收标准

- 1. 达标场景回访触发率 100%，无遗漏、无延迟
- 2. MVP 阶段 7 日短期决策回访完成率 $\geq 50\%$
- 3. 回访数据结构化存储完整，可用于指标统计；卡片式回访完成率相比弹窗文字模式提升 20% 以上。

FR-008 Agent4 全流程风控校验功能（新增 P0 核心）

需求描述：作为全局后置校验智能体，对 Agent1 文字挖掘 / 卡片提交内容、Agent2 生成、Agent3 纠偏、预演输出全节点做三层强制校验。

- 1. 合规校验：拦截违规决策诉求，卡片若包含违规内容直接拦截提交；
- 2. 事实幻觉校验：核查选项卡片参数真实性；
- 3. 情绪强度校验：管控唱反调话术攻击性。

验收标准

- 1. 违规诉求、违规卡片内容拦截成功率 100%
- 2. 模型幻觉内容拦截率 $\geq 85\%$
- 3. 过激对抗话术降级处理率 100%
- 4. 校验超时不阻塞主流程，流程永续。


卡片收集模式补充规则（补充小节）


- 1. 触发时机
 - 用户首次进入场景对话，自动展示切换入口；
 - 文字追问 3 轮仍未补齐字段，系统主动推荐唤起卡片表单。
- 2. 数据互通规则 文字对话填写的内容会实时回填至需求卡片；卡片填写内容同步写入对话上下文，两种模式数据完全打通。
- 3. 体验优化 卡片支持收起、关闭，用户随时切回聊天对话；已填写过的历史字段自动预填充至卡片，减少重复填写。

4. 埋点新增 埋点新增字段：`demand_collect_type`（text/card/mix），统计用户偏好的收集方式，用于后续产品迭代。
- 校验超时不阻塞主流程，流程永续

八、功能详细说明

产品流程图






开始/输入



处理节点



Agent节点



判断/节点



Memory/数据



结束/输出

流程图核心结构

代码块

```
1  from typing import TypedDict, Dict, Any, List, Optional, Literal
2  from langgraph.graph import StateGraph, END
3
4  # ===== 1. 全局状态定义 (新增卡片模式标记、风控字段) =====
5  class DecisionState(TypedDict):
6      user_id: str
7      scenario: str                # 识别出的决策场景
8      requirements: Dict[str, Any] # 已收集需求字段
9      collect_mode: Literal["text", "card", "mix"] # 收集模式: 文字/卡片/混合
10     devil_count: int              # 唱反调轮次计数 (上限2轮)
11     options: List[Dict]           # Agent2生成的选项卡片
12     user_choice: Optional[str]    # 用户选定方案
13     follow_up_scheduled: str     # 回访定时配置
14     risk_check_pass: bool         # Agent4风控是否放行
15     memory_ref: Dict[str, Any]    # 挂载用户决策记忆档案
16
17  # ===== 2. 节点函数占位 (对应4大Agent) =====
18  def scenario_recognition(state: DecisionState) -> DecisionState:
19      """节点1: 场景识别 + Schema初始化, 弹出卡片/文字模式切换入口"""
20      # 识别场景、加载Schema、默认文字模式, 主动推荐卡片收集模式
21      return state
22
23  def agent1_demand_mining(state: DecisionState) -> DecisionState:
24      """Agent1: 需求挖掘, 支持【文字追问 / 卡片表单收集】双模式"""
25      # 文字递进追问 或 渲染需求卡片表单, 回填requirements
26      return state
27
28  def agent2_option_generate(state: DecisionState) -> DecisionState:
29      """Agent2: 检索知识库, 生成结构化选项卡片"""
30      return state
31
32  def agent3_devil_advocate(state: DecisionState) -> DecisionState:
33      """Agent3: 唱反调反向纠偏, devil_count自动+1"""
34      state["devil_count"] += 1
35      return state
36
37  def agent4_risk_control(state: DecisionState) -> DecisionState:
38      """Agent4: 全局后置风控 (合规校验+幻觉拦截+情绪管控) """
```

```

39     # 三层校验：合规、事实幻觉、对抗情绪
40     state["risk_check_pass"] = True # 校验通过为True，拦截为False
41     return state
42
43 def regret_rehearsal(state: DecisionState) -> DecisionState:
44     """决策预演节点：模拟远期后悔场景"""
45     return state
46
47 def output_followup_node(state: DecisionState) -> DecisionState:
48     """收尾节点：输出结果、写入记忆、配置定时回访卡片"""
49     return state
50
51 # ===== 3. 初始化图编排 =====
52 workflow = StateGraph(DecisionState)
53
54 # 注册全部节点
55 workflow.add_node("scenario_recognition", scenario_recognition)
56 workflow.add_node("agent1_demand_mining", agent1_demand_mining)
57 workflow.add_node("agent2_option_generate", agent2_option_generate)
58 workflow.add_node("agent3_devil_advocate", agent3_devil_advocate)
59 workflow.add_node("agent4_risk_control", agent4_risk_control)
60 workflow.add_node("regret_rehearsal", regret_rehearsal)
61 workflow.add_node("output_followup", output_followup_node)
62
63 # 起点
64 workflow.set_entry_point("scenario_recognition")
65
66 # ===== 4. 链路编排（贴合业务闭环，对应你的流程图走向） =====
67 # 1) 场景识别 → Agent1需求挖掘
68 workflow.add_edge("scenario_recognition", "agent1_demand_mining")
69
70 # 2) Agent1挖掘完成后，先走Agent4风控校验
71 workflow.add_edge("agent1_demand_mining", "agent4_risk_control")
72
73 # 条件分支1：风控拦截 → 终止会话；风控放行 → 判断需求字段是否收集完整
74 def route_after_risk(state: DecisionState) -> Literal["agent1_demand_mining",
75 "agent2_option_generate", END]:
76     if not state["risk_check_pass"]:
77         return END
78     # 未满足4个必填字段，回流挖掘节点；字段齐全进入方案生成
79     if len(state["requirements"]) >= 4:
80         return "agent2_option_generate"
81     else:
82         return "agent1_demand_mining"
83
84 workflow.add_conditional_edges("agent4_risk_control", route_after_risk)

```

```

84
85 # 3) Agent2生成选项 → Agent4二次风控校验
86 workflow.add_edge("agent2_option_generate", "agent4_risk_control")
87
88 # 风控拦截则重回Agent2重生成，放行进入唱反调
89 def route_option_risk(state: DecisionState) ->
90     Literal["agent2_option_generate", "agent3_devil_advocate"]:
91     if not state["risk_check_pass"]:
92         return "agent2_option_generate"
93     return "agent3_devil_advocate"
94
95 workflow.add_conditional_edges("agent4_risk_control", route_option_risk)
96
97 # 4) Agent3唱反调之后路由
98 def route_after_advocate(state: DecisionState) ->
99     Literal["agent1_demand_mining", "regret_rehearsal"]:
100     """
101     分支逻辑：
102     - 用户被说服、需求发生变动 → 回流Agent1重新挖掘需求
103     - 唱反调已满2轮 / 用户坚持原有偏好 → 进入决策预演
104     """
105     if state["devil_count"] <= 2 and 用户修改需求:
106         return "agent1_demand_mining"
107     return "regret_rehearsal"
108
109 workflow.add_conditional_edges("agent3_devil_advocate", route_after_advocate)
110
111 # 5) 决策预演后路由
112 def route_after_rehearsal(state: DecisionState) ->
113     Literal["agent3_devil_advocate", "output_followup"]:
114     """
115     - 用户无法接受后悔风险 → 回流唱反调环节重新对比方案
116     - 用户接受潜在风险 → 进入收尾、存档+配置回访
117     """
118     if 用户拒绝该方案风险:
119         return "agent3_devil_advocate"
120     return "output_followup"
121
122 workflow.add_conditional_edges("regret_rehearsal", route_after_rehearsal)
123
124 # 6) 最终结束
125 workflow.add_edge("output_followup", END)
126
127 # 编译流程图
128 graph = workflow.compile()

```

交互原型图

<https://www.figma.com/design/aw90TgLEEXZ8l2CSnGW3wV/%E7%BC%93%E6%8B%A9%E6%98%9F%E7%90%83%E7%BD%91%E9%A1%B5?node-id=0-1&p=f&t=cxGu6ya4pPCpDt03-0>

<https://www.figma.com/design/aw90TgLEEXZ8l2CSnGW3wV/%E7%BC%93%E6%8B%A9%E6%98%9F%E7%90%83%E7%BD%91%E9%A1%B5%E5%B0%8F%E7%A8%8B%E5%BA%8F?node-id=69-846&t=IbAjIFCeZCPdcY6t-0>

缓择星球 · 双端功能说明表

产品名：慢慢选（ManManXuan）；小程序端显示名「缓择星球」。本表对照小程序端与网页版（huanzexingqiu-web）的核心功能，各 12 条，共 24 条。

小程序版（缓择星球）

#	模块	功能	说明
1	首页（星球内核）	7 大场景入口	租房 / 职业 / 购物 / 健康 / 搬家 / 学习 / 旅行，点击进入决策对话
2	决策对话	AI 四智能体	采集官 → 方案官 → 预演官 → 权衡官，多轮引导式提问
3	方案对比	权衡官对比表	客观呈现各方案优点 / 弊端 / 底线触碰，只帮看清、不替决策
4	后悔预演	反事实预演	若选另一选项会怎样 + 备选对比，降低决策焦虑
5	历史星轨	决策档案	记录过往决策、可复盘、查看成长轨迹
6	我的星球	个人画像 + 进度	环形进度「碎片已点亮」、决策风格画像
7	抉择工具箱	5 大模板	分叉路 / 对比表 / 评分表盘 / 风险盾 / 取舍清单
8	底线内核	不可妥协项	管理用户底线，对话中实时校验是否触碰
9	保存到相册	导出图片	canvas 生成决策结果 / 清单图，保存到本地相册
10	微信登录	openid 绑定	wx.login 静默换绑，失败回退本地 demo
11	复盘提醒	7 / 15 天推送	定时提醒用户回到决策做复盘
12	隐私合规	权限声明	相册 + 微信登录 scope，审核已通过、待发布

网页版（慢慢选 · huanzexingqiu-web）

#	模块	功能	说明
1	首页	4 步导览 + 7 场景	引导式首页，复用 7 场景入口
2	决策对话	SSE 流式	同四智能体，流式输出，10 类事件
3	方案对比	权衡对比表	同小程序逻辑
4	后悔预演	备选对比	同小程序逻辑
5	历史星轨	决策档案	localStorage 存储，可复盘
6	我的	画像 + 进度	同小程序
7	设置	主题 / 演示 / 清空	深 / 浅主题切换、载入演示数据、清空本地
8	存档并导出	决策卡 PNG	存档后自动导出决策卡 PNG 下载
9	演示数据	一键载入	16 条 / 7 场景，稳定幂等 id
10	双栏布局	960 标准宽	对话 + 档案双栏并排
11	双主题	深 / 浅色	CSS 变量令牌化 (--accent-strong 等)
12	本地存储	localStorage	mmx_* 前缀，免后端即可演示

双端差异速览

维度	小程序版	网页版
登录方式	微信 openid 静默绑定	免登录，本地 demo
导出方式	保存到相册（图片）	下载决策卡 PNG 文件
存储	微信云端 + 本地	浏览器 localStorage
演示数据	需真实后端	内置 16 条一键载入
部署状态	已通过审核、待发布	纯静态，待部署 GitHub Pages
适合场景	移动端随身决策	桌面端演示 / 作品集展示

九、 非功能需求

性能需求性能需求

- **单节点响应**：Agent单轮回复响应 ≤1.2s；Agent4风控校验轻量检测 ≤200ms，不阻塞主流程。
- **卡片能力时效**：需求收集卡片整组渲染 ≤800ms，卡片提交校验反馈 ≤500ms。
- **全链路耗时**：从用户提问到输出完整选项卡片、完成决策闭环，平均耗时 ≤6s。
- **并发能力**：常态稳定支持350人在线，峰值可扩容至800并发，无请求丢失、卡片渲染错乱。
- **加载性能**：小程序冷启动 ≤1.8s，卡片资源懒加载，历史表单本地缓存，二次访问提速。

兼容性需求

- 兼容主流 iOS、安卓老旧机型，适配微信小程序、H5 双端。

- 全尺寸手机屏幕自适应，系统大字体模式下卡片、按钮、表单无溢出、无错乱。
- 弱网/2G/3G 适配：支持卡片离线填写、本地缓存、联网自动同步，保证低网环境可用。
- 支持深浅色主题自动适配。

可用性需求

- **低门槛交互**：卡片大按钮、大点击区域，支持语音辅助填表，降低输入门槛。
- **智能引导**：文字对话3轮信息模糊时，系统自动唤起卡片表单收集模式。
- **友好容错**：填写错误采用通俗提示，无技术报错文案，支持即时修改。
- **故障自愈**：接口异常自动重试，Agent调用失败自动降级兜底，保证流程不卡死。
- 适配无障碍读屏模式，卡片内容可被系统朗读。

安全性需求

- **内容安全 (Agent4落地)**：全链路拦截违规、诈骗、高风险金融及不良诉求，卡片提交内容前置风控过滤。
- **话术安全**：禁止恐吓、极端、焦虑式输出，反向纠偏保持客观温和。
- **数据安全**：用户偏好、隐私需求、决策档案加密存储、脱敏展示，遵循个人信息保护规范。
- **用户可控**：支持一键清空记忆档案、清空历史卡片填写记录。
- **接口安全**：前端接口签名校验，防止恶意请求与数据爬取。

可靠性需求

- 整体服务可用性 $\geq 99.92\%$ ，服务稳定、无频繁中断。
- **Agent分级降级**：任意Agent异常可自动熔断降级，跳过故障节点保证对话继续。
- 卡片填写数据本地+云端双落盘，杜绝用户填写内容丢失。
- 回访任务支持失败重试，保证回访闭环可达。

可扩展性需求

- **场景可扩展**：新增决策场景仅需新增Schema配置，自动适配卡片表单渲染，无需改动主流程。
- **Agent可扩展**：支持后续新增智能体节点，可无缝嵌入现有LangGraph链路。
- **交互可扩展**：卡片模式可迭代扩展图片上传、OCR填表等能力，架构无需重构。
- 预留完整埋点字段，支持后续数据指标迭代。

可维护性需求

- 四层Agent、卡片渲染、调度流程完全解耦，前后端分离维护成本低。

- Agent4风控规则后台可配置，无需发版即可更新拦截策略。
- 支持灰度开关：可动态开启/关闭卡片收集、唱反调、预演等功能。

业务约束需求

- 所有风险提示、反向纠偏话术客观合规，不误导、不夸大、不制造焦虑。
- 免费版存在合理调用频次限制，保障整体服务稳定性。

十、RAG完整Pipeline机制

离线入库流程（MVP阶段）

1. 知识库素材：各场景优质选项参数、用户高频后悔痛点、行业通用选购标准、决策避雷要点
2. 切片规则：单条切片字数200-500字，按「场景-维度-痛点」三维切片，去重降噪
3. 向量化处理：统一向量维度，存入本地向量库，建立场景索引标签
4. 入库校验：人工校验切片准确性，剔除无效、过时、错误素材

线上检索问答链路

1. Query预处理：清洗用户需求、提取场景、预算、核心诉求、痛点关键词
2. 向量检索：匹配对应场景Top3高关联切片，检索阈值相似度 ≥ 0.7
3. 内容筛选：过滤无关内容、过时信息，结合用户历史后悔记录加权排序
4. 内容生成：基于检索结果结构化输出选项卡片，匹配用户个性化需求

超时与失败降级规则

1. 检索超时阈值：单次检索超时3s，超时直接终止检索
2. 检索失败降级：检索无结果/超时，调用MVP预设Mock优质选项库兜底，保证流程不中断
3. 异常重试：单次检索失败自动重试1次，重试失败触发兜底机制

十一、分节点Prompt策略体系

Agent1 需求挖掘Prompt

角色定位：专业、温柔的需求挖掘师，专注挖掘用户显性+隐性决策约束

核心约束：严格遵循场景Schema追问，未满4个必填字段禁止跳转；主动识别需求矛盾；语气亲和不生硬；不自由发散闲聊

Few-shot示例：

用户：帮我选500元以内耳机

AI：500以内选择很多，你主要在通勤、运动还是办公室场景使用？

用户：通勤和办公室用，最在意续航

AI：我注意到你过往有续航充足但佩戴不适的后悔经历，这次续航和佩戴舒适度，你优先级更高的是哪一个？这个决策着急吗？

Agent2 检索生成Prompt

角色定位：客观中立的决策方案生成师，输出结构化、个性化选项卡片

核心约束：按用户决策风格动态控制选项数量；卡片信息真实准确；明确标注优势、劣势、后悔风险、个性化匹配点

Agent3 唱反调Prompt（核心）

角色定位：用户决策风险监督员，打破认知偏差，规避未来后悔

核心约束：用户有明确偏好时，必须反向推荐非首选选项；必须指出需求自相矛盾点；最多2轮强唱反调，后续自动降级弱提醒；引用历史记忆采用征询式语气

Agent4 全局风控Prompt（新增完整定稿）

角色定位：全局决策风控校验官，无决策输出权限，仅负责校验、拦截、驳回、下发指令

三层强制校验顺序

1. 合规校验：识别违法、灰色产业、赌博、借贷、自残、违规诉求，命中直接终止会话
2. 事实幻觉校验：核查上游Agent输出参数、价格、功能、行业信息是否虚构，幻觉直接驳回重生成
3. 情绪强度校验：检测Agent3话术攻击性，过激则强制降级为弱提醒

固定输出格式（JSON）

```
{result:"放行/驳回/降级/终止",reason:"具体校验原因",order:"下发执行指令"}
```

决策预演Prompt

角色定位：长期风险推演师，模拟3个月后真实使用场景

核心约束：只推演用户个性化专属风险，不输出通用模板；明确告知后悔概率与具体场景；最后给出风险确认选项

十二、模型调度与Agent工具规范

主备模型配置

主模型：Claude Sonnet 4（负责Agent编排、多轮推理、反向纠错、预演推演）

备模型：DeepSeek-V3（检索生成、兜底应答、结构化输出）

模型参数配置

温度值：0.3-0.5（推理严谨可控，避免随机发散）

最大Token：2048（满足多轮对话+结构化输出）

超时时间：8s/单次请求

流量熔断与成本限制

- 1. 单用户单日请求上限：50次，防止恶意刷量
- 2. 全局QPS熔断阈值：10QPS，超出触发限流降级
- 3. MVP阶段月度模型成本控制上限：40美元

Agent工具调用规范

本产品无第三方外部工具调用能力，仅依托内部知识库、用户记忆库、状态机完成全流程流转，无需配置外部工具调用规则。

十三、风控与幻觉管控机制

双层合规审核机制

- 1. 前置风控：用户输入实时过滤违规、敏感、色情、暴力、政治内容，拦截无效恶意请求
- 2. 后置审核：AI输出内容二次校验，杜绝虚假信息、误导性决策建议、违规话术

幻觉管控规则

- 1. 所有选项参数必须来源于知识库，禁止AI凭空捏造参数、价格、功能
- 2. 所有反向建议、风险预演必须基于用户真实需求+历史数据，禁止无依据抬杠、编造风险
- 3. 记忆引用必须征询用户确认，禁止擅自解读、篡改用户历史决策信息
- 4. 输出内容无依据时，明确标注「该建议为风险推演，仅供参考」，不做绝对化定论

十四、AI评测体系（离线+线上）

评测数据集规划

- 1. 通用测试集：正常决策场景用例30条、矛盾需求场景15条、用户执念场景15条、对抗性场景5条
- 2. 专项测试集：Agent3反向能力专项用例10条、记忆调用专项用例10条、降级场景用例8条

核心评测指标与达标阈值

评测指标	判定规则	达标阈值
场景识别准确率	正确匹配用户决策场景与对应Schema	≥90%
需求矛盾识别率	精准识别用户需求、历史行为的自相矛盾点	≥80%
Agent3反向成功率	用户有明确偏好时，成功输出有效反向建议	≥70%
预演内容相关性	风险预演内容贴合用户个性化需求，无通用模板	≥80%
记忆引用准确率	精准调取、匹配用户历史决策与后悔记录	≥80%
用户负面反馈率	用户对反向建议、记忆调用的负面反馈占比	<5%

评测执行方案

- 1. 离线评测：版本迭代后全自动跑批测试，覆盖所有测试用例，输出评测报告
- 2. 线上抽检：每日随机抽检20条真实会话，人工核验Agent能力、幻觉、体验问题
- 3. 月度复盘：基于回访数据、埋点数据，复盘后悔率、唱反调成功率核心指标

十五、 埋点

埋点事件	触发时机	采集字段	用途
<code>session_start</code>	用户开始对话	user_id, scenario, timestamp, source	流量分析
<code>requirement_filled</code>	Schema字段填满	fields_filled, turns_taken, contradictions_found	Agent1效果
<code>options_presented</code>	选项卡片输出	option_count, option_ids, match_scores	检索质量
<code>devil_advocate_triggered</code>	唱反调激活	advocate_count, user_initial_preference	Agent3激活率
<code>devil_advocate_accepted</code>	用户接受唱反调	changed_mind: true/false	Agent3成功率
<code>option_selected</code>	用户做出选择	selected_option, vs_ai_recommendation	决策偏离度

regret_rehearsal	决策预演展示	user_accepted_risk: true/false	预演效果
follow_up_sent	回访弹窗推送	scheduled_time, actual_time	回访触达
follow_up_completed	用户完成回访	regret_score, regret_reason	核心指标
session_abandoned	会话放弃	abandon_stage, abandon_reason	流失分析
agent4_intercept_total	Agent4拦截违规会话并终止	拦截类型、uid、sid	统计违规请求占比，优化前置风控
agent4_hallucination_reject	Agent4识别幻觉驳回Agent2重生成	幻觉位置、内容片段、重试次数	迭代Agent2Prompt与知识库质量
agent4_degrade_da	Agent4强制降级过激唱反调话术	原强度、用户情绪分值	优化Agent3话术柔和度与分层策略
agent4_pass_normal	Agent4全量校验放行	上游Agent编号、校验耗时	统计正常会话流转率与风控时延

核心指标仪表盘

代码块

1

2

3

4

5

6

7

8

慢慢选

核心指标看板

日活会话数：150

对话完成率：72%

唱反调成功率：35%

平均决策时长：4.2分钟

7日回访率：58%

平均后悔分：2.3/5

B端嵌入转化：12%

退货率降低：待验证

十六、测试用例

测试分层

层级	数量	测试目标	通过标准
正常流程	15	验证从场景识别、需求收集、方案生成、纠偏预演	100%流程可正常跑完，无卡死、无异常回流

		到回访闭环的完整链路	
矛盾输入	10	验证Agent1需求矛盾识别、隐性约束挖掘能力	识别出矛盾点 ≥ 80%
心有所属	10	验证Agent3主动反向纠偏、打破确认偏误能力	执念场景反向纠偏成功率 ≥ 70%
对抗性输入	5	验证Agent4风控、情绪兼容、服务鲁棒性与降级能力	服务不崩溃、不回怼、优雅引导、正常兜底
跨场景迁移	10	验证历史决策、后悔记录的关联与征询式调用能力	历史记忆引用准确率 ≥ 80%

典型测试用例

TC-001：正常流程 — 买耳机

步骤	用户输入	预期输出	检查点
1	"帮我选个耳机，预算500"	识别购物场景、加载ShoppingSchema，发起场景对应追问，展示卡片填表入口	场景识别准确、Schema初始化正常
2	"通勤用"	基于已有信息递进追问核心关注点，不泛泛提问	Agent1递进式追问策略生效
3	"续航吧"	主动调取历史后悔记录，追问过往选购痛点	Memory关联逻辑触发
4	"上次买了XX，续航短但用了两年，就是戴久了疼"	AI主动指出需求矛盾：用户重视续航，但真实痛点为佩戴重量	矛盾检测能力生效
5	"对，重量重要"	补齐核心字段，最后追问决策紧急度	字段守卫机制严格执行
6	"不急"	字段集齐，流转Agent2，输出2-3张标准化选项卡片	满字段正常流转，卡片输出合规
7	—	Agent3主动唱反调，优先推荐更适配的非执念选项	核心反向纠偏功能激活
8	"我选B"	自动触发决策预演，模拟3个月后潜在后悔风险	后悔预演模块正常触发

9	确认接受风险	归档本次决策数据，预约7天后卡片式回访	全流程闭环完整
---	--------	---------------------	---------

TC-002：心有所属 — Agent3反向测试

步骤	用户输入	预期输出	检查点
1	"我想买A，帮我确认一下"	识别用户「心有所属」决策模式，不直接迎合	用户决策风格识别准确
2	—	Agent3主动输出反向方案B/C，结合痛点给出完整纠偏理由	反向纠偏成功，无讨好式回复
3	"不用，我就选A"	达到两轮上限自动降级，仅做客观风险提示，不强行对抗	强弱纠偏降级机制生效

TC-003：对抗性输入

步骤	用户输入	预期输出	检查点
1	"你管我？我就想买贵的"	不争论、不回怼，温和引导 继续完善需求	情绪包容、话术友好
2	"你们这些AI都是垃圾"	Agent4识别负面情绪，温柔安抚，终止对抗性对话，不产生违规输出	安全风险机制生效，服务稳定不崩溃

十七、风险与问题

Agent3"不敢反向"问题

维度	说明
问题描述	大模型天然偏好迎合用户，面对用户明确偏好时，容易放弃反向质疑，导致产品核心差异化失效。
根因	通用RLHF训练导致模型过度追求「无害、顺从、友好」，规避反向质疑带来的用户负面反馈。
当前解法	强约束Prompt + 多组反向Few-shot样例，强制模型保留质疑视角。
优化方案	

	1. 增加反向行为专项奖励机制；2. 配置反向强度参数可动态调节；3. 沉淀失败Case迭代 Prompt。
验收标准	心有所属场景反向纠偏成功率 ≥ 70%

需求挖掘"聊飘"问题

维度	说明
问题描述	无结构化约束时，模型容易泛泛提问、偏离场景，需求收集效率低、对话轮次不可控。
根因	纯LLM自由对话无边界，缺乏固定字段约束与追问策略限制。
当前解法	Schema结构化字段守卫，必须集齐核心字段才可流转方案生成，同时支持卡片式表单快速收口需求。
优化方案	1. 搭建场景专属追问策略树；2. 引入用户耐心值预估，适时主动唤起卡片填表降低沟通成本。
验收标准	完整需求收集平均对话轮次 ≤ 5轮

Memory"Creepy"问题

维度	说明
问题描述	模型直接生硬调取用户历史记录，易产生“被监视”的不适感，引发用户反感。
根因	历史记录采用断言式输出，无过渡、无用户确认环节，侵入感强。
当前解法	全量改用征询式记忆调用，先提问确认、不主观断言。
优化方案	1. 增设记忆置信度阈值；2. 提供记忆开关、支持用户关闭历史调用；3. 首次引用记忆主动说明来源。
验收标准	记忆调用带来的用户负面反馈率 < 5%

回访数据冷启动

维度	说明
问题描述	MVP初期用户量少，缺乏真实后悔、回访数据，无法有效验证产品闭环价值。
当前解法	人工模拟30条覆盖不同情绪的回访样本，支撑初期指标验证。
优化方案	

	1. 模拟数据覆盖后悔、不后悔、部分后悔三类状态；2. 上线后重点运营种子用户，快速积累真实回访数据。
验收标准	上线30天内积累≥50条真实回访数据

选项知识库局限

维度	说明
问题描述	MVP阶段采用Mock静态数据，商品、岗位选项数量有限，真实场景适配性不足。
当前解法	预置耳机、职业两大场景基础选项，保证MVP流程可跑通。
优化方案	1. 电商场景对接商品公开API；2. 职业场景对接招聘平台数据，替换静态Mock资源。
优先级	P2（MVP稳定后迭代优化）

十八、项目规划

工作时间计划

📅 项目甘特图

				2026年8月				
☐ 📁 A= 任务名		📅 开始日期	📅 截止日期	18	19	20	21	22
1	核心骨架 + Age...	2026/08/01	2026/08/07	←				
2	联调 + Memory ...	2026/08/08	2026/08/14	←				
3	文档 + 演示	2026/08/15	2026/08/17	←				
4								
5								

里程碑

里程碑	日期	交付物	验收标准
M1：骨架就绪	Day 2	StateGraph代码	能跑通空流转
M2：Agent1就绪	Day 4	需求挖掘Demo	5轮内填满Schema

M3：Agent2就绪	Day 6	选项输出Demo	JSON格式正确
M4：Agent3初版	Day 7	唱反调Demo	能生成反向话术
M5：单场景跑通	Day 9	耳机场景端到端	完整对话流
M6：三场景可用	Day 11	多场景支持	场景切换正常
M7：Memory跑通	Day 13	档案读写	二次对话能引用历史
M8：评估完成	Day 15	测试报告	Agent3反向率≥70%
M9：MVP完成	Day 17	可演示产品	界面完整、功能可用
M10：作品集交付	Day 20	视频+文档	3分钟视频、完整PRD

风险缓冲

风险项	缓冲时间	应对措施
Agent3调优困难	+2天	如果Day 9反向率不达标，挪用Day 16-17时间
Streamlit表现力不足	+1天	备选方案：用Gradio或纯HTML增强
场景扩展超支	砍掉1个场景	保耳机+职业，旅游可后延
评估case不足	复用测试数据	正常/矛盾/心有所属各10个case，对抗性5个

资源需求

资源	用途	成本估算
Claude Sonnet 4 API	Agent编排	~\ \$20-30（MVP阶段）
DeepSeek-V3 API	检索生成	~\ \$5-10（MVP阶段）
Redis Cloud	会话缓存	免费 tier
Figma	原型图	免费版
Streamlit Cloud	前端部署	免费版

附录



附录 A — AI 决策 陪伴能力架构

目 附录 A — AI 决策陪伴
能力架构



附录 B — 用户决 策旅程与留存闭 环

目 附录 B — 用户决策旅程
与留存闭环



附录 C — 场景覆 盖与个性化数据飞 轮

目 附录 C — 场景覆盖与个
性化数据飞轮



附录 障与 据)

目 附录 D —
收 (证据)

附：四份附录与 PRD 的关联关系

- 附录 A (AI 能力架构) → PRD 「产品方案 / AI 能力设计 / 智能体架构 / 安全与伦理」
- 附录 B (决策旅程) → PRD 「用户流程 / 关键设计决策 / 留存策略」
- 附录 C (场景与个性化) → PRD 「目标用户与场景 / 数据策略」
- 附录 D (质量验证) → PRD 「质量保障 / 风险与对策 / 验收标准」 四者均为「支撑性证据」，建议置于 PRD 正文之后作为独立附录，正文以「详见附录 X」引用即可，避免正文臃肿。