

评测体系一页纸

用途：把「118条测试集/ 91.5%」做成可验收、可追问的专业指标体系

项目：小办·企业行政RAG问答Agent | 2026-08扣子 workflows 实测

1.一句话

118条分层用例、人工逐条核对，端到端通过率91.5%；其中库内高频（L1）24条全中、100%。

指标不是跑分跑出来的，是我按"员工真实会怎么问"设计出来、一条条对着制度原文判的。

2.判定口径：什么算"通过"（最重要）

每条用例由人工对照制度原文，判三档：

判定	标准	说明
通过 (pass)	结论正确且依据正确（引用到对条款）且无编造	三条件同时满足
部分通过 (half)	结论方向对，但依据缺失/不完整/未给全步骤	例如答对了天数但没给申请路径
不通过 (fail)	结论错/编造（幻觉）/ 该答却兜底 /该兜底却硬答	后两类是我重点盯的失败模式

通过率口径：(通过+部分通过) /总数 = 108 / 118 = 91.5%

若部分通过按0.5计：(107 +0.5) / 118 = 91.1%（两种口径差异< 0.5pt，不影响结论）

我会主动说清这个口径——"半通过算通过"是我的选择，差异我也算给你看，

这比只报一个数更可信。

3.为什么分层：整体准确率是虚荣指标

分层	条数	测什么	类比
L0极端边界	16	反常识问法、多条件叠加、数值临界	考"敢不敢认怂"
L1库内高频	24	标准问法（和知识库表述接近）	考"快、准、稳"
L2全量正常	78	日常变体（口语、换说法、简写）	考"泛化能力"

分层的价值：L1全对但L0全错，整体看着也有80%，但真实体验是崩的——

只有分层才能暴露短板在哪一层，才知道该修检索、修路由还是修兜底。

4.实测结果（2026-08 ·扣子 workflows ·人工逐条核对）

分层	用例	通过率
L1库内高频	24	100% (24/24)
L2全量正常（合并L1+其余）	102	93.1% (95/102)
L0极端边界	16	75-81%
整体	118	91.5%

迭代轨迹（同一套测试集，不换题）：

47.5%（关键词/字符匹配）->71.2%（本地语义引擎）->91.5%（LLM分层 workflow）

每一步都是"改一处、跑一遍、看分层指标"，防止按下葫芦浮起瓢。

5.映射到专业指标（诚实口径）

RAG场景常见的坑是混淆"检索指标"和"端到端指标"。我的口径如下：

专业指标	我的对应	数值/状态
端到端通过率（Accuracy）	结论+依据+无编造三条件同时满足	91.5%（118条）
错误拒绝率（False Rejection /漏答）	"库里有答案却走兜底"	修复前多例->修复后核心业务0例
错误接受率（False Acceptance /幻觉）	无依据却硬答/编造来源	重度幻觉0（冲突兜底+严禁编造+分层兜底话术）
检索有效性（非严格IR Recall）	片段里是否含"业务正文"	用有效性判定代替相似度阈值（这是关键改造）
鲁棒性（Robustness）	L0极端边界层	75-81%（已列改进项，认怂优先于硬答）

我会主动澄清的一点：

我测的是端到端通过率，不是学术意义的IR召回率。

如果企业要做检索侧召回率，需要额外标注"标准答案chunk集合"再算Recall@K——

我在测试集里没做这层标注，这是当前评测的边界，我不会拿它冒充召回率。

6. badcase闭环：发现->归类->定位->修复->回归

跑118条回归时，反复出现同一类问题：明明库里有答案，却答错或兜底了。

逐条定位后揪出三个"守门人"，每个配一次修复+一次回归：

#	守门人（问题）	典型badcase	根因	修复	回归结果
①	标准问答匹配	TC-S04「新员工办公用品」只回半句；TC-S06命中却返回空串	用"字符集合重叠"当语义，换说法就跌破阈值；同义词未参与匹配	标准QA接入向量库（standard_qa_kb）；命中空答案跳过；提示词加"严禁相似度阈值兜底"	同义改写可命中，该类归零
②	检索->兜底路由	TC-S05「病假工资」库里有"超6个月按60%"却全局兜底	启发式"长度<50或无数字就判无效"误杀短条款	判定改为是否含业务正文；路由依据从"向量分"改成"有没有正文"	有答案却兜底被堵死
③	兜底节点	命中标准QA却输出空回答	兜底节点根本不读检索返回的答案文本	兜底改为消费真实检索结果；命中业务正文强制走正常回答	焊死链路，核心业务零误答

闭环纪律：每个修复后都跑同一套118条，看分层指标有没有搬家（不能L1涨了L0崩了）。

7.常见疑问与口径说明

问：91.5%怎么算的？

118条人工逐条核对，三条件判定：结论对+依据对+无编造。

通过107条、部分通过1条，按"部分通过算通过"是91.5%；

如果部分通过按半计是91.1%，两种口径我都算过，差异很小。

问：为什么不做召回率/ F1？

我测的是端到端通过率，不是检索侧召回率。

要做Recall@K得先标注每条case的标准答案chunk集合——这层标注我现在没做，

所以我不拿91.5%冒充召回率。如果岗位需要，我可以补这层标注把F1也算出来。

问：L0只有75-81%，不丢人吗？

不丢人，而且是设计选择。极端边界层我优先"认怂"而不是"硬答"——
答错制度的代价远高于说"没查到，建议问HR"。

剩下的25%我已经列了改进项（追问补全关键信息、边界值专项校验），

这也正是我在做的「追问-打开-细读-验证」办事循环要解决的问题。

问：118条够吗？

对三大场景（假期/报销/办公用品）的高频问法是够的，能覆盖主要决策路径与边界。

局限是：单企业单制度库，换一套制度需要重新标注；

我的做法是把它做成可迁移模板——换文档、按同样三层结构补case即可。

问：这套评测和业务的连接是什么？

分层指标直接对应体验：L1决定"高频问题省不省事"、L2决定"换说法还灵不灵"、

L0决定"出格问题会不会闯祸"。老板关心的不是91.5%，是"HR还要不要重复答疑"——

L1 100%就是这件事的答案。

8.一句话总结

我的评测不是"跑个分"，是用一套可回归、可分层、可定位的分层测试集，把模型的不确定性变成可验收的工程指标，

并且每个失败case都能追到具体节点、配有具体修复动作。