

小办·迭代方案与复盘（v1.0 -> V2升级规划）

作品集案例说明-一句话定位：用118条回归测试集驱动「设计预估->分层实测」闭环，把企业行政问答准确率从单点预估97%落到可验收的L1 100% / L2 93.1%；并在此基础上规划V2，把产品从「问答工具」升级为「办事Agent」。

数据底盘：63条标准QA知识库+3份制度原文+118条回归测试集（覆盖请假/报销/宴请/考勤等高频场景）

诚实标注：第一~八章为已实测内容；第九~十一章为V2方向性规划（PRD与验收标准已设计，尚未开发实测），涉及「规划中」的能力一律不写成已上线。

一、版本演进总览

版本	时间	核心目标	关键改动	结果
v1.0	2026-07-20	上线MVP	单链路单兜底（问题理解->向量检索->直接生成->简单兜底）	准确率约72%，HR每周介入5+次
v1.5	2026-07-27	架构升级	新增4节点：制度冲突校验/循环重试/权重融合/三级兜底	硬答率28% -> 3%，目标准确率80% -> 97%（预估）
v1.5.1	2026-08-21	根因修复	标准QA接知识库向量检索（standard_qa_kb）+字符重叠兜底；QA库30 -> 63条；阈值0.8 -> 0.78；补4个回归用例	解决「换说法不命中」「检索到却兜底」
v2.0 demo	2026-08-22	作品集可体验	前端5轮迭代：同义改写/多问题拆分/过渡兜底/假种降权/数字boost/宴请特判	118条测试47.5% -> 71.2%（纯字符上限）
扣子实测	2026-08-23	跑通全量验收	扣子 workflow 跑测+分层口径（L1 / L2 / L0）替代单点预估	L1 100% (24/24) / L2 93.1% (95/102) / L0 75%
V2.0（规划）	2026-09	办事闭环	复用13节点+ 新增2节点+1循环判断：权限前置过滤/信息完整性判断+追问、打开-细读、验证回流	规划中，未实测；V1的91.5%作为不变量

二、v1.0 -> v1.5：架构升级迭代

动机

- v1.0单链路单兜底，遇到制度冲突/模糊问题硬答，准确率仅72%
- HR每周介入5+次（重复咨询/口径不一）
- 痛点：①无标准QA库，全靠向量检索；②混合问句不拆分；③冲突校验粗糙；④检索仅重试1次

方案

- 新增4个节点，形成「问题改写/拆分分类/检索/冲突校验/重试/权重融合/三级兜底」链路：
- 制度冲突校验节点：前置拦截阶梯规则误冲突
 - 循环重试检索节点：最多2次扩大召回
 - 权重融合节点：向量+关键词双路合并
 - 三级兜底节点：mid_fallback + global_fallback

结果

- 硬答率从28%降到3%（设计目标达成）
- 30条高频易错问答建立标准输出逻辑
- 问答准确率设计目标：80% -> 97%（V1.5 PRD预估）

复盘要点·一

「97%是阶段设计目标值，尚未经过全量实测」——这是第一版预估，未跑过真实回归集；后续4个真实回归用例（TC-S04 / 05 / 06 / K01）恰好挂在这套机制下，直接推动了v1.5.1根因修复与分层口径的建立。

三、v1.5 ->v1.5.1：根因修复（2026-08-21）

现象：4个真实回归用例

用例	实际分支	失败原因
TC-S04新员工办公用品	正常回答	答「可申请」未列全电脑/键盘等清单
TC-S05病假超6月工资	全局兜底	标准QA字符重叠0.46漏，向量又过严
TC-S06加班22点打车	标准QA命中但答案为空	normal_answer不做空值兜底
TC-K01宴请2000元	正常回答但部分命中	LLM没做数值比较（2000 < 5000无需总经理）

根因诊断：「三守门人」缺陷

守门人①标准QA字符重叠匹配（致命）

- _calculate_keyword_similarity是字面字符集相交/并集，命名SEMANTIC_MATCH_THRESHOLD但名不副实
- 池子里现成的synonym_questions字段完全未使用（代码只拿question比对）
- query_rewrite改写后稀释重叠比，反向产生负作用

守门人②检索->兜底路由信号与「能否回答」脱节

- has_valid_content用「长度< 50或无数字/关键词」启发式判有效->短条款（"病假超6月按60%发放"仅12字）被误杀
- condition_check用向量分0.2 / 0.6划档，与"答案是否在文本里"无关

守门人③兜底节点不读答案文本

- fallback_answer_node输入只有user_input，完全不看knowledge_retrieval
- mid_fallback只抽标题就输出固定话术

值得补充的是，normal_answer_node已有一道「含业务正文禁止兜底」的前置校验，但被上游门①门②架空，未能生效。

修复方案：A / B / C / D

方案	改动	修复目标	工作量
A	standard_qa_match纳入synonym_questions匹配（阈值0.5）；空答案条目跳过；加A-补丁（核心词防误命中）	TC-S04 / 05 / 06 + 整批同义改写	1h
B	merge_retrieval +secondary_retrieval_is_title_only放宽：含业务关键词的短片段视为有效	短条款误杀	30min
C	condition_check新增最高优先级防护：knowledge_retrieval含业务正文>= 2个关键词强制走normal	有答案却兜底	30min
D（彻底）	标准QA接入扣子standard_qa_kb知识库做向量检索	换说法稳定命中+同义改写	半天（含建表+导入）

实施：A / B / C当晚全量上线，并给出D的前端版本；D方案（彻底换语义向量）交给扣子后台实施。PRD同步修订到V1.5.1。

复盘要点·二

「机制升级一定要落到代码链路，不能只看指标」——4个FAIL单看不严重（4 / 118 = 3.4%），但根因都是架构层缺陷，不修会蔓延。D方案（彻底换语义向量）才是治本，但实施成本高，需要扣子后台支持，因此先做A / B / C兜底、再排期D。

四、v1.5.1 ->v2.0 demo引擎：纯前端能力上限验证

动机

- 作品集要「可体验」，但纯前端能否撑住118条测试集？
- 若纯前端做不到，就走LLM后端；若能做到，给作品集提供「秒开」体验

方法：5轮迭代逼近上限

轮次	改动	通过率
基线	字符引擎初始版	47.5% (56 / 118)
第1轮	domainGroups词表加宽+qDom空放宽+加isDirectAnswer +加isSceneQuestion场景词	57.6%
第2轮	query_rewrite同义改写（60+条映射：老婆生孩子->陪产假、请jia ->请假）+多问题拆分+过渡兜底mid_fallback	66.1%
第3轮	假种降权（年假问->事假条目x0.4）+数字共现boost（"3天" ->短期病假3天+0.15）+forceBanquet宴请特判+病假6月裁剪80%	67.8%
第4轮	金额边界= +max数字+病假>=6 +5条口语映射补全	66.1%
第5轮	年假区间连字符（en dash ->hyphen 1-10年）+SCENE_WORDS补"修改请假"等5条	71.2% (84 / 118)

复盘要点·三

「纯字符引擎的天花板约在75%」——7项改进后仍差29%，全部集中在：

- 数据缺口（约7条，库里无对应条款）
- 库原文vs测试集字面矛盾（约8条）
- 复合问句语义（约7条，需LLM拆分）
- 否定/口语推理（约7条，需LLM判定）
- 边缘值/符号（约5条，需LLM改写）

结论：LLM不是「锦上添花」，而是「补剩余29%的必要能力」。这正是作品集「双引擎」叙事的起点——本地引擎快但71%，真LLM后端补到95%+。

五、v2.0 ->扣子实测：分层口径与实战验证

动机

- PRD里的「97%」是V1.5阶段预估，从未实测
- 单点准确率会被极端提问拉低、被判定口径争议掩盖
- 面试核心问题：「能不能到97%？」

设计：三层口径替代单点预估

层级	口径	目标线	验收方式
L1库内高频	标准QA库可直接命中的问题	>= 97%	24 / 24或按1位小数
L2全量正常	全部正常提问（含L1）	>= 90%	102过>= 92
L0极端与边界	空输入/噪声/边缘值/日期/完全域外	单独报告	附兜底说明

打标规则写入模板（118条已L0 = 16 / L1 = 24 / L2 = 78打标完毕，可复现）。

实测：2026-08-23全量118例

层级	用例数	pass	实测	目标	判定
L1库内高频	24	24	100%	>= 97%	达成（满分）
L2全量正常（L1 +其余）	102	95	93.1%	>= 90%	达成
L0极端与边界	16	12	75%（含半pass 81.2%）	单独报告	附说明

剩余11条全为兜底话术/改写覆盖类（核心命中零失误）

- EC过渡兜底4条：EC07 / 08 / 10 / 11（库内确无细则，应走过渡话术）
- F无匹配2条：F01合作公寓/ F06推荐电脑（应走全局兜底）
- 改写/闲聊2条：W03消假（"销假"未映射）/ NO03情绪闲聊未剥离
- 边界/噪声3条：EB03 0元/ ER02噪声/ F10薪资（半pass）

复盘要点·四（最关键）

「分层口径才是AI准确率的正确表达方式」——单点预估（97%）永远会被人追问"怎么算的"；分层之后：

- L1 100% =核心能力满分
- L2 93.1% =长尾覆盖良好
- L0单独报告=边界不可控属正常

面试被问「97%怎么来的」——直接答「118例实测：库内高频24 / 24满分，全量正常93.1%，极端单独归类」，数据全部有据可查。

六、关键决策复盘

决策1：从「单点预估」到「分层口径」

- 原状：V1.5 PRD把「准确率>= 97%」写成单点预估
- 修正：拆为L1 / L2 / L0三层，L0单独报告不进承诺
- 收益：从被挑战（"97%怎么来的？”）到可验收（有118条测试集支撑）

决策2：demo双引擎叙事

- 发现：纯字符引擎71%是上限，剩余29%必须LLM
- 决策：作品集demo =本地引擎（快）+LangChain后端（真LLM），右上角切换
- 收益：访客秒开体验+面试演示「本地71% /真LLM 93%+」成长故事

决策3：边界用例必须单列（L0）

- 原状：把「0元报销」「正好5000元」等边界用例塞进主指标，会拉低数字

- 修正：L0极端边界16条单独归类（空输入/噪声/边缘值/日期/完全域外）
- 收益：主指标93.1%是真「正常提问」的93.1%，不被边缘拉低

决策4：根因vs症状

- 教训：v1.5升级加4节点是**症状缓解**（硬答率28% -> 3%），但根因是「字符重叠匹配非语义」与「兜底节点不读答案」
- 修正：v1.5.1直接修根因（standard_qa_kb向量检索+mid_fallback实质兜底）

决策5：反复迭代时的「测试集即合同」

- 经验：118条测试集=验收合同；每次迭代都用同一份集跑，能直接看到N个FAIL -> 原因->修复
- 工具：xlsx加「分层层级」「demo实测」「扣子实测」三列，跑测即填表

七、经验沉淀（可复用到其他产品迭代）

1. 任何「AI准确率」都要分层谈——核心命中率（L1）+长尾覆盖率（L2）+边界/域外（L0）=完整质量画像；单点预估永远会被挑战，分层口径可验收。
2. 纯字符引擎的上限约75%——启发式匹配解决高频精确问题；复合语义、否定推理、边缘值必须LLM。
3. 测试集=验收合同——构造100+条带「预期包含/禁止出现关键词」的回归集；每次迭代跑同一份集，看N个FAIL -> 分类归因；集本身与引擎版本一起迭代。
4. 根因诊断要落到代码链路，不能只看指标——4个FAIL看似仅3.4%，但根因是架构层缺陷；用「现象->根因->解法」三段式归因。
5. PRD修订要保留「历史+标注实测」——版本日志保留V1.5「80% -> 97%」原文（那是历史）；实测达成后用【实测注】标注，体现「从预估到背书」的迭代诚意。
6. 决策记录要附「动机->方案->结果」三段式——不只写「做了什么」，要写「为什么做、怎么选、结果如何、复盘经验」。

八、V2升级规划：从「问答工具」到「办事Agent」（规划中）

版本：V2.0（规划中，未进入开发）

基准：V1.5.1（已上线实测：118例分层评测，L1 100% / L2 93.1% /整体91.5%）

诚实标注：本章为方向性PRD（用户故事+需求+验收标准已设计），非已实现版本。

8.1变更摘要 (v1.5.1 ->v2.0)

项	V1.5.1（当前，已实测）	V2.0（规划）
产品形态	单轮问答（RAG混合检索+分层兜底）	办事闭环（追问-打开-细读-验证四步循环+权限透传）
对用户价值	问得到答案	像真人办事一样：先问清、再找到、细读、核验后给结论
对HR/管理价值	减轻重复答疑	制度合规可追溯+权限隔离（解决不敢上线的顾虑）
技术主线	13节点线性工作流（手写状态机）	复用13节点+新增2节点+1判断循环，零推倒
竞品维度	检索准确率	办事闭环能力（破RAG内卷）
状态	已落地（91.5%）	规划中

一句话：V1.5.1证明“答得准”，V2回答“办得成”——同一个底座，加一层Agent循环和权限，就把产品从工具抬到企业级。

8.2背景与机会（行业判断）

- 企业知识问答主流还停留在"单轮检索->生成"的RAG 1.0：切片策略、向量模型、Top-K内卷严重，天花板低、同质化高。
- 两个被忽视的核心痛点：
 1. 体验断层：员工查制度是"澄清诉求->定位章节->细读条款->核对例外"的完整行为链，单轮问答只能吐片段。
 2. 合规顾虑：通用RAG全库检索，无法对接组织权限——制度越权查看是企业不敢上线问答的核心顾虑。
- 机会：把竞争维度从"检索准确率"移到"办事闭环+权限合规"，直接打B端决策人痛点。

8.3目标与非目标

目标

- G1：模糊/缺关键信息的问题，从"瞎检索"变为"先澄清再办"（新增追问闭环）。
- G2：复杂制度问题，回答从"片段结论"升级为"细读+核验后的完整结论"。
- G3：知识库按角色/职级/部门可见范围过滤，消除越权查看风险（一期：文档级）。
- G4：V1的118条测试集全部回归通过，不因升级回退。

非目标（刻意不做，防范围蔓延）

- 不做端到端大模型自由决策（保住状态机可控性，防幻觉回升）。
- 一期不做字段级/行级细粒度权限（先文档级跑通）。
- 不新增业务场景（V2只把行政/人事/报销跑透，场景复制放V3+）。
- 不做"连环追问"体验（追问必须极度克制）。

8.4用户故事

#	用户故事	对应能力	优先级
US-01	作为员工，我问"请客吃饭怎么报销"没提金额，希望AI先问我一句"费用多少/谁请客"，而不是直接瞎答	信息完整性判断+克制追问	P0
US-02	作为员工，问到具体条款时，希望AI先告诉我这是《差旅制度》第三章的内容"，再展开细则	打开（章节定位+文档内导航）	P0
US-03	作为员工，A条款和B条款看起来矛盾时，希望AI核验并提示"两条款适用条件不同"，而不是选一个硬答	验证（冲突/边界/例外交叉校验）	P0
US-04	作为经理，查制度时只应看到权限范围内内容；高管薪酬等敏感条款不应返回给我	权限前置过滤（文档级）	P1
US-05	作为HR，希望每次AI回答都可追溯（依据哪条制度、用户角色），便于审计合规	链路留痕/可审计	P1
US-06	作为员工，补充金额后AI应接着上一轮继续算，而不是把我当新用户重问一遍	多轮上下文衔接（复用V1）	P0

8.5功能需求（含验收标准）

FR-1权限前置过滤节点（新增，代码/规则节点）· P1

- 检索前根据user_role / user_level / department过滤可见知识库范围。
- 一期口径：文档级/知识库级，不做行级。
- 缺省策略：未匹配到角色->最小权限（只可见全员制度），宁严勿松。
- 验收：AC1 "高管薪酬" +普通员工->命中该制度；AC2同问句+HR ->正常返回；AC3 V1 118条不涉密部分过滤后内容一致（不误伤）。

FR-2信息完整性判断节点（新增，大模型节点）· P0

- 接在问题改写/拆分分类之后，判断是否缺少**关键必填字段**（金额/时长/人员类型/对象类别）。
- 输出JSON: {"is_complete": true|false, "missing_fields": ["金额"], "reason": "..."}。
- 克制追问硬约束：只对影响答案分支的必填字段缺失才追问；场景A（可归类直接答）不追问；场景B（真缺关键条件）追问一次，一次只问最重要的1项。
- 验收：AC1 "请客吃饭花了5000要总经理批吗" -> 直接进主链路；AC2 "请客吃饭要谁审批" -> 触发一次追问；AC3 V1 118条回归不回退。

FR-3追问交互（复用多轮上下文+新分支）· P0

- is_complete=false -> 主动追问->用户补充->回到改写节点重走主链路；追问内容由reason驱动，生成一句人话+一个示例。
- 验收：追问后同会话补全->走到正确分支；超过1轮仍不补->放弃追问转"过渡兜底"，绝不无限追问。

FR-4打开-细读两段式召回（改造检索粒度）· P0

- 打开：首轮检索优先返回"章节/目录级"结果（定位《制度名·章节》）。
- 细读：基于已定位章节做定向细粒度召回条款原文（检索范围从全库收敛到该章节）。
- 验收：AC1回答包含"依据位置（制度名+章节号）"；AC2章节内细节（例外条款、边界值）召回完整。

FR-5验证环节回流（改造冲突校验输出）· P1

- 复用V1冲突校验+边界临界校验；新增"校验存疑->自动回到细读补检索关联条款"的回流边（最多1次，防死循环）。
- 验收：AC1两条款疑似矛盾->补检索到第三条解释条款并给完整结论；AC2仍无法消解->明示"需HR确认"，走冲突兜底不硬答。

8.6非功能需求

维度	要求	验证方式
成本	单次问答不因追问/循环显著抬升；追问仅P0关键字段触发	成本账模型更新+实测抽样
性能	全链路（含追问回流）端到端< 8s	压测抽样
评测	V1 118条全回归+新增追问/权限用例入集（预计118 -> 140+）	分层口径不变：L0 / L1 / L2
合规	链路可审计（角色+命中制度+依据）；越权访问留痕	埋点字段扩展
可控	workflow状态机结构不推翻，V2全部为新增节点+复用节点重排	架构评审

8.7指标体系（V2新增过程指标）

沿用V1分层（L1 100% / L2 93.1% /整体91.5%）作为**不变量**，新增V2专属过程指标：

指标	定义	目标（规划）
追问触发率	追问次数/总会话数	5%-15%（克制：只该问的问）
追问后补全率	追问后用户补全并走通的比例	>= 60%
单会话平均LLM调用	含追问回流后	<= 1.3 x V1基线
越权召回率	权限用例中命中无权制度的比例	0%
边界/冲突问题准确率	原118条中L0边界子集	较V1的75%提升至>= 85%（目标值，上线后实测回填）

8.8里程碑（规划，未排期承诺）

- M1：FR-2 +FR-3（追问闭环）在3场景上线->追问边界用例进评测集回归。
- M2：FR-4（打开-细读）优化召回粒度->边界/细节类准确率复测。
- M3：FR-1 +FR-5（权限前置+验证回流）->权限用例集全量通过+合规留痕上线。
- M4：140+用例全量回归，输出V2分层实测报告。

8.9风险与对策

风险	对策
追问过度惹烦用户	硬约束：仅关键必填缺失、一次一问、超1轮转兜底（FR-2 / FR-3）
Agent化后幻觉回升	对内保持状态机、不外放自由决策；回流最多1次防死循环
权限误伤正常回答	一期文档级+最小权限缺省+AC3防误伤回归
V1准确率回退	118条全量回归作为每个里程碑的准入闸门

九、V2节点落地设计（扣子画布/ LangChain通用）

上一份《小办Agent升级_新增节点与提示词》是LangChain工程版（Python节点函数+state.py +graph.py），扣子版是画布版（大模型节点Prompt +代码节点+条件分支）。两者逻辑完全一致，只是载体不同：扣子版用于快速验证和作品集展示，LangChain版用于自托管落地，Prompt可两份通用。

9.1升级总览：画布新增3节点+1条件分支

新增件	类型	位置	作用
权限前置过滤	代码节点	检索之前	按角色过滤可见知识库，输出allowed_kbs
信息完整性判断	大模型节点	问题改写/拆分类之后	输出is_complete +missing_fields +reason
主动追问	大模型节点	条件分支false分支	生成一句人话追问+示例
条件分支	判断节点	完整性判断之后	is_complete ->主链路/ ->追问

链路：问题改写->拆分类->完整性判断 ->（分支）->主链路（权限过滤 ->检索->打开-细读->生成->验证回流）或主动追问。

9.2权限前置过滤（代码节点）

- 输入：user_role / user_level / department +知识库清单。
- 规则：按角色-制度矩阵过滤；未匹配->最小权限（只可见全员制度）。
- 输出：allowed_kbs（知识库id列表）+fallback_flag。

9.3信息完整性判断（大模型节点）

- 角色：判断问句是否缺少影响答案分支的关键必填字段。
- 关键必填（按业务域）：报销->金额档次/宴请对象；假期->时长档位/假期类型；办公用品->物品类别。
- 克制原则（最高优先级）：能按场景归类直接答的模糊问法->不追问；只问影响答案分支的必填字段；一次只问1项并说明为什么需要。
- 输出：严格JSON，只输出JSON，禁止其他字符与代码块标记。

9.4主动追问（大模型节点）

- 目标：把missing_fields转成一句自然口语追问+一个示例，帮用户知道怎么补。

- 输出约束：不答原问题、不带markdown /前缀、不出现"作为AI"等表述。

9.5条件分支与变量连线

- 分支条件：is_complete == true ->主链路；false ->追问节点->回到改写节点。
- 变量：missing_fields、reason、ask_count（追问轮次，>1转兜底）。

9.6克制原则（落地红线）

- 追问极度克制：能答就答，不为了"显得智能"而追问。
- 权限先轻后重：一期文档级，跑通再做字段级。
- 场景先深耕再复制：行政/人事/报销跑透，再谈扩展。

十、V2验收：测试设计与Smoke Test

10.1测试原则

- 按节点测：权限过滤/完整性判断/追问/条件分支各自独立断言。
- L0 / L1 / L2分层不变：沿用V1口径，新增用例归入相应分层。
- 指标标三档口径：实测/估算/规划，不含糊。

10.2权限前置过滤（6条）

覆盖employee / hr / finance / admin /空角色，断言allowed_kbs子集正确与回退策略（空角色->最小权限）。

10.3信息完整性判断（7条）

覆盖报销/假期/办公用品/泛咨询/极端输入，断言JSON可解析、不矛盾、泛咨询不追问。

10.4主动追问（4条）

断言追问不答原问题、语气自然、无markdown /前缀。

10.5条件分支与端到端链路（4条E2E）

覆盖：权限排除后仍可正常答、追问不硬答、追问超1轮转兜底、泛咨询直走主链路。

10.6上线前必跑Smoke Test

上述21条合并为上线前最小集；判定口径先写死再跑，避免边跑边改标准。

十一、复盘要点·五（V2阶段）

「把竞争维度从指标移到场景闭环，是AI产品做深的正确姿势」

- V1阶段我在"准确率"这个维度上做到了91.5%，但这是行业所有人都在卷的维度，天花板可见。
- V2我把问题重新定义为："员工查制度是一个完整行为链（澄清->定位->细读->核验），而单轮问答只覆盖了最后一小段。"
- 因此V2不推倒V1的13节点状态机，只加2个节点+1个循环判断——工程改动可控，但产品叙事从"答得准"升级为"办得成"，并首次把组织权限合规纳入检索链路。
- 这也是我标注"规划中"的原因：方向已出PRD与验收标准，但没有实测数据前，我不会把它写进成果数字里。

十二、附：交付物清单

文档	用途	位置
《标准QA问答系统_部分命中根因分析》	根因诊断报告	工作区
《问答系统_修改方案_可直接贴扣子》	A / B / C / D修复方案	工作区
《小办测试集118条_基线报告》	测试集基线+v2升级明细	工作区
《小办分层实测模板_118条》	三层口径定义+跑测步骤+扣子实测结果	工作区
《PRD-小办V1.5.1修订版》（docx / html）	PRD已回填实测数字	工作区
《PRD V2 ·小办办事Agent升级版（规划稿）》	V2方向性PRD +验收标准	工作区
《小办Agent化升级：新增节点与提示词》（扣子版/ LangChain版）	3新节点Prompt与代码	工作区
xiaoban.html（作品集demo主页）	5轮迭代后的前端引擎	经历翻译官网页/

整理日期：2026-09-09
第一期（v1.0 -扣子实测）整理于2026-08-23；V2规划章节于2026-09-09并入
适用范围：作品集《缓择星球》《经历翻译官》《小办》三件套的作品迭代档案