

小办 · 迭代方案与复盘（v1.0 – 扣子实测）

作品集案例说明 · 一句话定位：用 118 条回归测试集驱动「设计预估 →

分层实测」闭环，把企业行政问答准确率从单点预估 97% 落到可验收的 **L1 100% / L2 93.1%**。

数据底盘：63 条标准 QA 知识库 + 3 份制度原文 + 118 条回归测试集（覆盖请假 / 报销 / 宴请 / 考勤等高频场景）

一、版本演进总览

版本	时间	核心目标	关键改动	结果（实测）
v1.0	2026-07-20	上线 MVP	单链路单兜底（问题理解 → 向量检索 → 直接生成 → 简单兜底）	准确率约 72%，HR 每周介入 5+ 次
v1.5	2026-07-27	架构升级	新增 4 节点：制度冲突校验 / 循环重试 / 权重融合 / 三级兜底	硬答率 28% → 3%，设计目标准确率 80% → 97%（预估）
v1.5.1	2026-08-21	根因修复	标准 QA 接知识库向量检索 + 字符重叠兜底；QA 库 30 → 63 条；阈值 0.8 → 0.78；补 4 个回归用例	解决「换说法不命中」「检索到却兜底」
v2.0 demo	2026-08-22	作品集可体验	前端 5 轮迭代：同义改写 / 多问题拆分 / 过渡兜底 / 假种降权 / 数字 boost / 宴请特判	118 条测试 47.5% → 71.2%（纯字符上限）
扣子实测	2026-08-23	跑通全量验收	扣子工作流跑测 + 分层口径（L1 / L2 / L0）替代单点预估	L1 100%（24/24）达成 / L2 93.1%（95/102）达成 / L0 75%

二、v1.0 → v1.5：架构升级迭代

动机

- v1.0 单链路单兜底，遇到制度冲突 / 模糊问题硬答，准确率仅 72%。
- HR 每周介入 5+ 次（重复咨询 / 口径不一）。
- 痛点：①无标准 QA 库，全靠向量检索；②混合问句不拆分；③冲突校验粗糙；④检索仅重试 1 次。

方案

新增 4 个节点，形成「问题改写 / 拆分分类 / 检索 / 冲突校验 / 重试 / 权重融合 / 三级兜底」链路：

- **制度冲突校验节点**：前置拦截阶梯规则误冲突。
- **循环重试检索节点**：最多 2 次扩大召回。
- **权重融合节点**：向量 + 关键词双路合并。
- **三级兜底节点**：mid_fallback + global_fallback。

结果

- 硬答率从 28% 降到 3%（设计目标达成）。
- 30 条高频易错问答建立标准输出逻辑。
- 问答准确率设计目标：80% → 97%（V1.5 PRD 预估）。

复盘要点 · 一

「97% 是阶段设计目标值，尚未经过全量实测」—— 这是第一版预估，未跑过真实回归集；后续 4 个真实回归用例（TC-S04 / 05 / 06 / K01）恰好挂在这套机制下，直接推动了 v1.5.1 根因修复与分层口径的建立。

三、v1.5 → v1.5.1：根因修复（2026-08-21）

现象：4 个真实回归用例

用例	实际分支	失败原因
TC-S04 新员工办公用品	正常回答	答「可申请」未列全电脑 / 键盘等清单
TC-S05 病假超 6 月工资	全局兜底	标准 QA 字符重叠 0.46 漏，向量又过严
TC-S06 加班 22 点打车	标准 QA 命中但答案为空	normal_answer 不做空值兜底
TC-K01 宴请 2000 元	正常回答但部分命中	LLM 没做数值比较（2000 < 5000 无需总经理）

根因诊断：「三守门人」缺陷

守门人 ① 标准 QA 字符重叠匹配（致命）

- `_calculate_keyword_similarity` 是字面字符集相交 / 并集，命名 SEMANTIC_MATCH_THRESHOLD 但名不副实。
- 池子里现成的 `synonym_questions` 字段完全未使用（代码只拿 `question` 比对）。
- `query_rewrite` 改写后稀释重叠比，反向产生负作用。

守门人 ② 检索 → 兜底路由信号与「能否回答」脱节

- `has_valid_content` 用「长度 < 50 或 无数字 / 关键词」启发式判有效 → 短条款（“病假超 6 月按 60% 发放”仅 12 字）被误杀。
- `condition_check` 用向量分 0.2 / 0.6 划档，与“答案是否在文本里”无关。

守门人 ③ 兜底节点不读答案文本

- `fallback_answer_node` 输入只有 `user_input`，完全不看 `knowledge_retrieval`。
- `mid_fallback` 只抽标题就输出固定话术。

值得补充的是，`normal_answer_node`

已有一道「含业务正文禁止兜底」的前置校验，但被上游门①门②架空，未能生效。

修复方案：A / B / C / D

方案	改动	修复目标	工作量
A	<code>standard_qa_match</code> 纳入 <code>synonym_questions</code> 匹配（阈值 0.5）；空答案条目跳过；加 A-补丁（核心词防误命中）	TC-S04 / 05 / 06 + 整批同义改写	1h
B	<code>merge_retrieval + secondary_retrieval_is_title_only</code> 放宽：含业务关键词的短片段视为有效	短条款误杀	30min
C	<code>condition_check</code> 新增最高优先级防护： <code>knowledge_retrieval</code> 含业务正文 ≥ 2 个关键词强制走 <code>normal</code>	有答案却兜底	30min
D（彻底）	标准 QA 接入扣子 <code>standard_qa_kb</code> 知识库做向量检索	换说法稳定命中 + 同义改写	半天（含建表 + 导入）

实施：A / B / C 当晚全量上线，并给出 D 的前端版本；D 方案（彻底换语义向量）交给扣子后台实施。PRD 同步修订到 V1.5.1。

复盘要点 · 二

「机制升级一定要落到代码链路，不能只看指标」—— 4 个 FAIL 单看不严重（4 / 118 =

3.4%），但根因都是架构层缺陷，不修会蔓延。D

方案（彻底换语义向量）才是治本，但实施成本高、需要扣子后台支持，因此先做 A / B / C 兜底、再排期 D。

四、v1.5.1 → v2.0 demo 引擎：纯前端能力上限验证

动机

- 作品集要「可体验」，但纯前端能否撑住 118 条测试集？
- 若纯前端做不到，就走 LLM 后端；若能做到，给作品集提供「秒开」体验。

方法：5 轮迭代逼近上限

轮次	改动	通过率
基线	字符引擎初始版	47.5% (56 / 118)
第 1 轮	domainGroups 词表加宽 + qDom 空放宽 + 加 isDirectAnswer + 加 isSceneQuestion 场景词	57.6%
第 2 轮	query_rewrite 同义改写 (60+ 条映射：老婆生孩子 → 陪产假、请 jia → 请假) + 多问题拆分 + 过渡兜底 mid_fallback	66.1%
第 3 轮	假种降权 (年假问 → 事假条目 ×0.4) + 数字共现 boost ("3 天" → 短期病假 3 天 +0.15) + forceBanquet 宴请特判 + 病假 6 月裁剪 80%	67.8%
第 4 轮	金额边界 = + max 数字 + 病假 >=6 + 5 条口语映射补全	66.1%
第 5 轮	年假区间连字符 (en dash → hyphen 1-10 年) + SCENE_WORDS 补"修改请假"等 5 条	71.2% (84 / 118)

复盘要点 · 三

「纯字符引擎的天花板约在 75%」—— 7 项改进后仍差 29%，全部集中在：

- 数据缺口 (约 7 条，库里无对应条款)
- 库原文 vs 测试集字面矛盾 (约 8 条)
- 复合问句语义 (约 7 条，需 LLM 拆分)
- 否定 / 口语推理 (约 7 条，需 LLM 判定)
- 边缘值 / 符号 (约 5 条，需 LLM 改写)

结论：LLM 不是「锦上添花」，而是「补剩余 29% 的必要能力」。这正是作品集「双引擎」叙事的起点 —— 本地引擎快但 71%，真 LLM 后端补到 95%+。

五、v2.0 → 扣子实测：分层口径与实战验证

动机

- PRD 里的「97%」是 V1.5 阶段预估，从未实测。
- 单点准确率会被极端提问拉低、被判定口径争议掩盖。
- 面试核心问题：「能不能到 97%？」

设计：三层口径替代单点预估

层级	口径	目标线	验收方式
L1 库内高频	标准 QA 库可直接命中的问题	≥ 97%	24 / 24 或按 1 位小数
L2 全量正常	全部正常提问 (含 L1)	≥ 90%	102 过 ≥ 92
L0 极端与边界	空输入 / 噪声 / 边缘值 / 日期 / 完全域外	单独报告	附兜底说明

打标规则写入模板 (118 条已 L0 = 16 / L1 = 24 / L2 = 78 打标完毕，可复现)。

实测：2026-08-23 全量 118 例

层级	用例数	pass	实测	目标	判定
L1 库内高频	24	24	100%	≥ 97%	达成 (满分)
L2 全量正常 (L1 + 其余)	102	95	93.1%	≥ 90%	达成

层级	用例数	pass	实测	目标	判定
L0 极端与边界	16	12	75% (含半 pass 81.2%)	单独报告	附说明

剩余 11 条全为兜底话术 / 改写覆盖类（核心命中零失误）：

- EC 过渡兜底 4 条：EC07 / 08 / 10 / 11（库内确无细则，应走过渡话术）
- F 无匹配 2 条：F01 合作公寓 / F06 推荐电脑（应走全局兜底）
- 改写 / 闲聊 2 条：W03 消假（"销假"未映射）/ NO03 情绪闲聊未剥离
- 边界 / 噪声 3 条：EB03 0 元 / ER02 噪声 / F10 薪资（半 pass）

复盘要点 · 四（最关键）

「分层口径才是 AI 准确率的正确表达方式」—— 单点预估（97%）永远会被人追问"怎么算的"；分层之后：

- L1 100% = 核心能力满分
- L2 93.1% = 长尾覆盖良好
- L0 单独报告 = 边界不可控属正常

面试被问「97% 怎么来的」—— 直接答「118 例实测：库内高频 24 / 24 满分，全量正常 93.1%，极端单独归类」，数据全部有据可查。

六、关键决策复盘

决策 1：从「单点预估」到「分层口径」

- 原状：V1.5 PRD 把「准确率 $\geq 97\%$ 」写成单点预估。
- 修正：拆为 L1 / L2 / L0 三层，L0 单独报告不进承诺。
- 收益：从被挑战（"97% 怎么来的？”）到可验收（有 118 条测试集支撑）。

决策 2：demo 双引擎叙事

- 发现：纯字符引擎 71% 是上限，剩余 29% 必须 LLM。
- 决策：作品集 demo = 本地引擎（快）+ LangChain 后端（真 LLM），右上角切换。
- 收益：访客秒开体验 + 面试演示「本地 71% / 真 LLM 93%+」成长故事。

决策 3：边界用例必须单列（L0）

- 原状：把「0 元报销」「正好 5000 元」等边界用例塞进主指标，会拉低数字。
- 修正：L0 极端边界 16 条单独归类（空输入 / 噪声 / 边缘值 / 日期 / 完全域外）。
- 收益：主指标 93.1% 是真「正常提问」的 93.1%，不被边缘拉低。

决策 4：根因 vs 症状

- 教训：v1.5 升级加 4 节点是症状缓解（硬答率 28% $\rightarrow$ 3%），但根因是「字符重叠匹配非语义」与「兜底节点不读答案」。
- 修正：v1.5.1 直接修根因（standard_qa_kb 向量检索 + mid_fallback 实质兜底）。

决策 5：反复迭代时的「测试集即合同」

- 经验：118 条测试集 = 验收合同；每次迭代都用同一份集跑，能直接看到 N 个 FAIL $\rightarrow$ 原因 $\rightarrow$ 修复。
- 工具：xlsx 加「分层层级」「demo 实测」「扣子实测」三列，跑测即填表。

七、经验沉淀（可复用到其他产品迭代）

1. 任何「AI 准确率」都要分层谈 —— 核心命中率（L1）+ 长尾覆盖率（L2）+ 边界 / 域外（L0）= 完整质量画像；单点预估永远会被挑战，分层口径可验收。
2. 纯字符引擎的上限约 75% —— 启发式匹配（关键词 / 字符重叠 / 词表）解决高频精确问题；复合语义、否定推理、边缘值必须 LLM；demo 给出「双引擎」叙事既诚实又有技术深度。

3. **测试集 = 验收合同** —— 构造 100+ 条带「预期包含 / 禁止出现关键词」的回归集；每次迭代跑同一份集，看 N 个 FAIL → 分类归因（数据缺口 / 库矛盾 / 语义 / 边缘）；集本身与引擎版本一起迭代。
4. **根因诊断要落到代码链路，不能只看指标** —— 4 个 FAIL 看似仅 3.4%，但根因是架构层缺陷；用「现象 → 根因 → 解法」三段式归因，不要只刷指标。
5. **PRD 修订要保留「历史 + 标注实测」** —— 版本日志保留 V1.5 「80% → 97%」原文（那是历史）；实测达成后用【实测注】段落标注「2026-08-23 扣子实测 100% / 93.1% / 75%」，体现「从预估到背书」的迭代诚意。
6. **决策记录要附「动机 → 方案 → 结果」三段式** —— 不只写「做了什么」，要写「为什么做、怎么选、结果如何、复盘经验」，文档才有真正的决策价值而非流水账。

八、附：交付物清单（本次迭代全套）

文档	用途	位置
《标准 QA 问答系统_部分命中根因分析》	根因诊断报告	工作区
《问答系统_修改方案_可直接贴扣子》	A / B / C / D 修复方案	工作区
《小办测试集 118 条_基线报告》	测试集基线 + v2 升级明细	工作区
《小办分层实测模板_118 条》	三层口径定义 + 跑测步骤 + 扣子实测结果	工作区
《小办 workflow 测试集 V1.5-分层版》	测试集分层 + demo + 扣子实测列	桌面 / 小办
《PRD-小办 V1.5.1 修订版》（docx / html）	PRD 已回填实测数字	工作区
xiaoban.html（作品集 demo 主页）	5 轮迭代后的前端引擎	经历翻译官网页 /

整理日期：2026-08-23 | 适用范围：作品集《缓择星球》《经历翻译官》《小办》三件套的作品迭代档案